As habilidades em análise de dados mais requisitadas no mercado de trabalho

Déborah Lima Scalioni[1]*; Renato Máximo Sátiro[2]

[1] Bacharel em Sistemas de Informação. Rua Antônio Jordão 443 – Residencial Jardim Califórnia; 13857-000 Estiva Gerbi, SP, Brasil
[2] Escola Superior de Agricultura "Luiz de Queiroz" - USP/ESALQ - Professor do curso de MBA em Data Science e Analytics – Rua Alexandre Herculano 120, sala T4 - 13418-445 Piracicaba, SP, Brasil.
Universidade Federal de Goiás - UFG. Doutor em Administração pelo Programa de Pós Graduação em Administração. Avenida Esperança s/n, Câmpus Samambaia - Prédio da Reitoria. 74690-900 Goiânia, GO, Brasil.
*autor correspondente: deborahscalioni@gmail.com

As habilidades em análise de dados mais requisitadas no mercado de trabalho

Resumo

Nos últimos anos, a área de dados teve um grande crescimento devido à transformação digital, impulsionada com o advento da pandemia. Consequentemente, a demanda por profissionais qualificados no mercado tem se tornado cada vez maior, e sendo assim, era esperado que a procura de estudantes pelas áreas de tecnologia fosse proporcional, porém, não é o que acontece. Além disso, cada empresa busca por diferentes requisitos e ainda existe muita divergência em relação as profissões de Cientista de Dados, Analista de Dados e Engenheiro de Dados, e quais os conhecimentos e habilidades necessárias para conquistar uma dessas posições no mercado. Esse estudo tem como objetivo consolidar o que é esperado dos profissionais da área de dados, com uma visão do mercado de trabalho, utilizando vagas publicadas por empresas no LinkedIn para analisar quais as habilidades na área de dados mais requisitadas pelas empresas no Brasil. O resultado desse estudo ajudará profissionais a se prepararem melhor para a real demanda do mercado, poderá ajudar empresas e instituições de ensino a entenderem quais habilidades possuem maior concorrência.
Palavras-chave: ciência de dados; **“**big data”; “analytics”, “business intelligence”; competências.

The most in-demand data analysis skills in the job market

Abstract

In recent years, the data area has had a great growth due to digital transformation, driven by the advent of the pandemic. Consequently, the demand for qualified professionals in the market has become increasing, and therefore, it was expected that the demand for students in the areas of technology would be proportional, however, this is not what happens. In addition, each company looks for different requirements and there is still a lot of divergence regarding the professions of Data Scientist, Data Analyst and Data Engineer, and what knowledge and skills are needed to conquer one of these positions in the market. This study aims to consolidate what is expected of data professionals, with a view of the job market, using jobs published by companies on LinkedIn to analyze which data skills are most required by companies in Brazil. The result of this study will help professionals to prepare themselves better for the real demand of the market, it can help companies and educational institutions to understand which skills have greater competition.
Keywords: data science; big data; analytics; business intelligence; competence.

Introdução

Devido à transformação digital, impulsionada com o advento da pandemia, as empresas geram enormes quantidades de dados todos os dias, por isso a necessidade de profissionais de análise de dados com as habilidades necessárias na área é cada vez mais competitiva entre as empresas. Os empregos de engenheiro de dados e cientista de dados estão entre as ocupações mais procuradas em 2020, com taxas de crescimento anual de 78% e 75%, respectivamente. Esse profissional construirá toda a infraestrutura de dados e implementará métodos para capturar, processar e realizar análises preventivas e preditivas

dentro da organização, podendo ser contratado por qualquer empresa que busca obter insights para a melhor tomada de decisão em grandes volumes de dados. (LinkedIn, 2020).

No entanto, esse crescimento substancial da área, associado à sua multidisciplinariedade, gerou uma confusão em relação às habilidades esperadas por esses profissionais e definições básicas de ferramentas, métodos e funções, o que gera custos altos para empregadores e profissionais, que precisam lidar com a falta de clareza nas descrições dos cargos nos processos seletivos (Fayyad e Hamutcu, 2020).

Observa-se, neste sentido, que as organizações buscam profissionais com habilidades técnicas e comportamentais, fundamentais no processo de transformação digital, e que forneçam informações que deem embasamento à tomada de decisão rápida e assertiva para que dessa forma elas se mantenham competitivas. Alguns exemplos dessas competências foram listados por Dubey e Gunasekaran (2015). As chamadas de “hard skills”, que podem ser aprendidas, como estatística, previsão, otimização, finanças, contabilidade financeira, marketing e as “soft skills”, que estão mais ligadas a personalidade, como liderança, trabalho em equipe, escuta, aprendizagem, atitude positiva, comunicação, relacionamento interpessoal, paciência e paixão.

Ademais, a lista de títulos de cargos no âmbito da análise e ciência de dados é diversa, como por exemplo, Analista de Dados, Engenheiro de Dados, Cientista de Dados, Arquiteto de Dados, Engenheiro de Big Data, Especialista em “Machine Learning”, etc. Há diversos caminhos possíveis e diversas habilidades, que podem coincidir ou não. No intuito de estreitar esse amplo universo, foram utilizados como referência “frameworks” os quais listaram e categorizaram os conhecimentos em dados para desenvolver uma lista que será utilizada para gerar as análises desse trabalho. (Fayyad e Hamutcu, 2020; Verma et al., 2019).

Considera-se ainda que a era digital e o distanciamento social, provocados pela COVID-19, também expandiram o uso de ferramentas online no recrutamento e seleção, aliado ao fato que tal modalidade se tornara o principal meio de atração de candidatos para a maioria das empresas. Dentre os principais impulsionadores dessa adoção incluem-se: a facilidade para candidatos, velocidade do processo, escalabilidade e alcance. Além disso, poder reagir mais rapidamente aos concorrentes, atraindo candidatos à frente da concorrência, pode ser ainda um diferencial competitivo para as organizações. (Pellaes, 2021). Devido à relevância das ferramentas digitais no mercado de trabalho, com o objetivo de analisar o processo descrito, buscando ainda fornecer informações concretas aos profissionais e empresas que buscam identificar o conhecimento mais procurado neste campo em crescimento, optou-se por utilizar o LinkedIn como fonte de dados para este estudo, pois é a maior rede profissional do mundo, amplamente utilizada por empresas e profissionais.

Esse trabalho tem o objetivo de identificar as habilidades mais relevantes das vagas do mercado de trabalho de dados, com um enfoque maior nos papéis de analista de dados ou “data analyst”, engenheiro de dados ou “data engineer” e cientista de dados ou “data scientist”, que hoje são as posições mais procuradas pelas empresas brasileiras. Buscou-se avaliar as diferenças dos requisitos entre essas posições e identificar se existe relação entre eles.

Material e Métodos

Foram utilizados quatro métodos principais: extração de dados por meio de “web scraping”, análise descritiva dos dados onde foram selecionadas e categorizadas as principais habilidades da área, com intuito de verificar as características das vagas publicadas. Em seguida, foi medida a associação entre essas habilidades e, por fim, foram utilizadas técnicas de “text mining”, para entender o contexto e extrair informações significativas dos campos textuais, determinando as palavras e frases mais utilizadas.

“Web scraping”

Segundo Zhao (2017), “web scraping” é uma técnica utilizada para extrair dados da internet e armazená-los para posterior utilização ou análise. Devido a grande quantidade de dados gerados online todos os dias, ela tem sido amplamente utilizada para coleta de grandes volumes de dados. Por ser de fácil customização e automatização, é a técnica de coleta de dados escolhida para este trabalho e, para implementá-la, utilizou-se a biblioteca Selenium e a linguagem Python.

Foram realizadas seis pesquisas na seção de vagas, utilizando o filtro de localização Brasil e as palavras-chave analista de dados, “data analyst”, engenheiro de dados, “data engineer”, cientista de dados e “data scientist”, com o intuito de abranger o máximo de vagas da área de dados possíveis, mesmo que publicada em outro idioma, como acontece em algumas empresas multinacionais.

A página de anúncios de vagas do LinkedIn carrega mais empregos ao rolar para baixo no navegador, no entanto, depois de seis rolagens ele não carrega mais automaticamente e é necessário clicar no botão ‘Ver mais vagas’ para carregar mais. Então, para satisfazer essa necessidade, foi criado um loop para rolar para baixo e clicar neste botão, considerando o total de vagas e a quantidade de novas vagas mostradas por clique. Após carregadas todas as vagas na página, foi gerado um segundo loop utilizando a “tag” da lista lateral (‘li’) para capturar as informações de cada vaga, como título, “link”, empresa, localização e data.

Para as demais informações, como, descrição da vaga, nível de experiência, tipo de emprego, função e setor, foi necessário clicar no título de cada vaga para obter o detalhamento à direita.

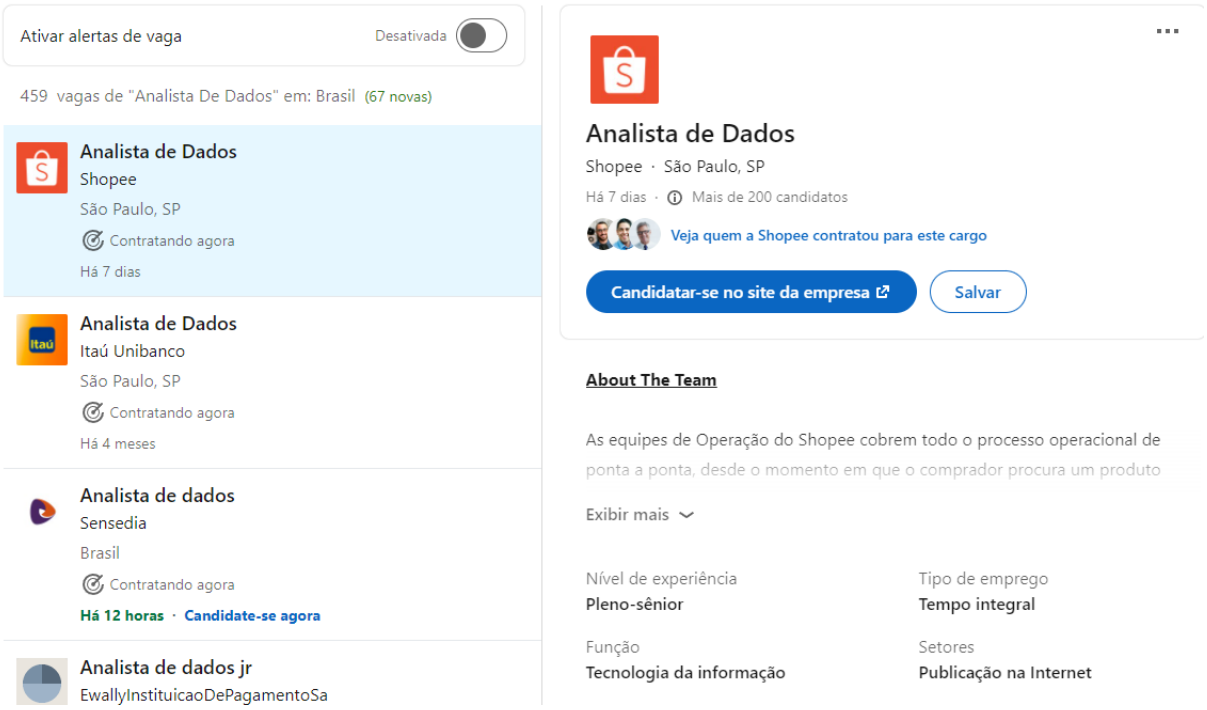


Figura 1. Página de vagas com busca por analista de dados do LinkedIn, 2022
Fonte: LinkedIn (2022)

Os dados foram carregados em “dataframes”, combinados, saneados e após remoção dos duplicados restaram 2498 publicações únicas.

Análise de dados

Reis e Reis (2002) afirmam que a análise descritiva é uma técnica utilizada para sintetizar e agrupar dados ou realizar comparações entre grupos de dados. É uma técnica adequada para compreensão das características nas distribuições de dados como os do LinkedIn, de natureza qualitativa, através de agrupamentos numéricos como porcentagens, índices e médias.

Foram analisadas a distribuição dos dados por localização, tipo, nível de senioridade, setor, empresa e o tipo de contrato. Além disso, como o objetivo era também identificar as diferenças e semelhanças entre as posições da área de dados, foi criada uma classificação nomeada de posição, através do título, e com isso foram realizadas diversas análises para cada posição separadamente e posteriormente de todas em conjunto para conseguir identificar as particularidades de cada uma, assim como da área como um todo.

As ferramentas descritivas utilizadas para representação dos dados são os gráficos e tabelas, que fornecem informações claras e facilmente interpretáveis.

Associação entre as habilidades

Inicialmente, foi necessário definir quais habilidades a pesquisa abrangeria. Com essa finalidade, e baseado nas referências anteriormente citadas, foram selecionadas as competências consideradas as principais utilizadas ou requeridas por profissionais da área. Elas foram agrupadas e categorizadas conforme abaixo:

- **Banco de Dados:** ETL, ELT, SQL, SQL Server, Oracle, Postgres, MySQL, NoSQL, Cassandra, MongoDB, Data Warehouse.
- **Dashboard e Relatórios:** Power BI, Tableau, Qlik, Business Objects, Excel, D3, Matplotlib, plotly.
- **Big Data:** Hadoop, Spark, Hive, Pig, HBase.
- **Programação:** Python, Scala, C/C++, C#, Java, .NET, HTML, PHP, Javascript.
- **Estatística:** R, SAS, SPSS, Stata, MATLAB, Regressão, Probabilidade.
- **Cloud:** Cloud, AWS, Azure, GCP.
- **Comportamentais:** Liderança, comunicação, relacionamento, apresentação, organização.

Para medir a associação entre as habilidades identificadas, foi utilizado um algoritmo para identificar a presença de cada termo no campo de descrição das vagas publicadas. Em alguns casos, foi necessário buscar várias versões de uma habilidade específica como, Power BI; PowerBI e PBI, “Data Warehouse” e DW, e também pelas traduções para vagas com texto em inglês como comunicação e “communication”. O algoritmo retornou um “dataframe” de colunas binárias, e então foi aplicado o “Phi Coefficient”, também conhecido em “machine learning como “Matthews correlation coefficient” [MCC], uma técnica que mostrou sua efetividade em estudos de diferentes áreas na medição da associação entre variáveis binárias. (Chicco e Jurman, 2020)

“Text mining”

“Text mining” ou mineração de texto, é o processo de obtenção de informações relevantes de fontes não estruturados, para identificar palavras-chave e outros padrões, transformando textos em variáveis numéricas e analisá-las com técnicas estatísticas. Foi utilizado a análise de n-grams, que identifica ocorrências de sequências de palavras em um

texto, para analisar mais profundamente os campos textuais título e descrição. (Schonlau et al., 2017)

A partir da categorização de competências e aplicando as técnicas citadas acima, foram apresentas as principais características das vagas no mercado de trabalho de dados, com foco principal em verificar quais são as habilidades mais requisitadas e se há diferenças entre as competências procuradas para os diferentes cargos de analistas, engenheiros e cientistas de dados. Ademais, verificar as relações entre habilidades e a identificar combinações de palavras por meio de técnicas de análise de texto, que orientará estudantes e profissionais na compreensão do que é melhor estudar e fornecerá embasamento para uma busca de vagas de trabalho mais assertiva.

Os resultados estão apresentados através de gráficos na próxima seção.

Resultados e Discussão

Análise descritiva

A análise descritiva dos dados buscou entender e resumir suas principais características. Ao analisar o título das oportunidades, notou-se uma grande pluralidade e foram necessários alguns tratamentos para criação do campo posição, como por exemplo, remoção de caracteres especiais, conversão para maiúsculo e para o idioma português e padronização dos termos de nível de senioridade. Dessa forma, verificou-se que 34,2% das oportunidades são relacionadas à engenheiro de dados, 22,3% à analista de dados e 12,9% à cientista de dados. As demais oportunidades classificadas como outro são na maioria engenheiro de software, engenheiro de “machine learning” e analistas de negócios.

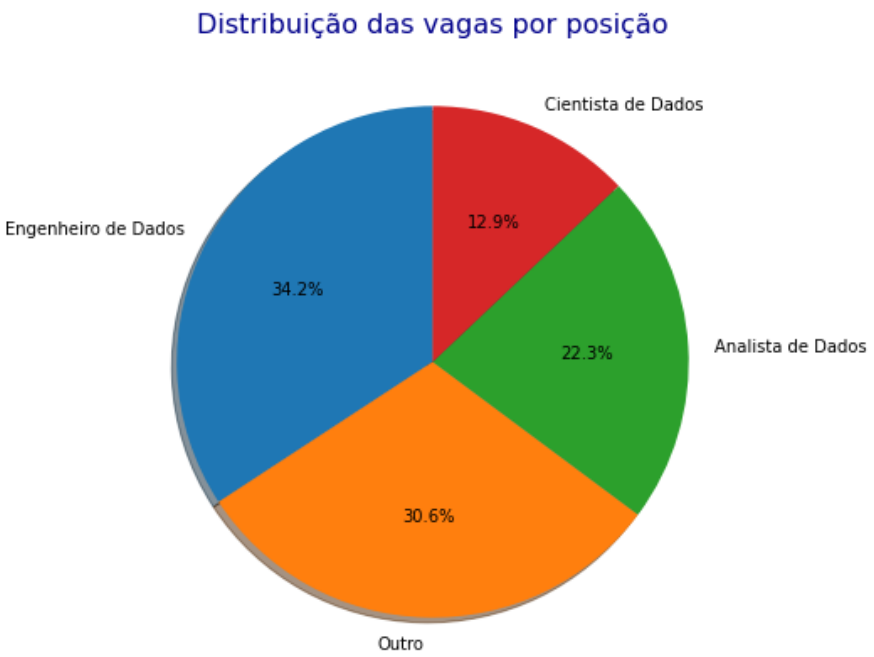


Figura 2. Distribuição das vagas por posição
Fonte: Resultados originais da pesquisa

Foi necessário também um tratamento da coluna localização, separando em cidade e estado, pois essa informação pode ser no nível de cidade, estado ou até mesmo país. A maioria das vagas de dados estão no estado de São Paulo 50,7%, considerando que 209 vagas estão no nível de país e por isso não aparecem no gráfico de distribuição por estado. Isso acontece, pois, muitas vagas da área são remotas.



Figura 3. Quantidade de vagas por estado
Fonte: Resultados originais da pesquisa

447 vagas não chegaram no nível de cidade, então removendo estes casos, abaixo é mostrado as 20 cidades com mais oportunidades na área de dados.

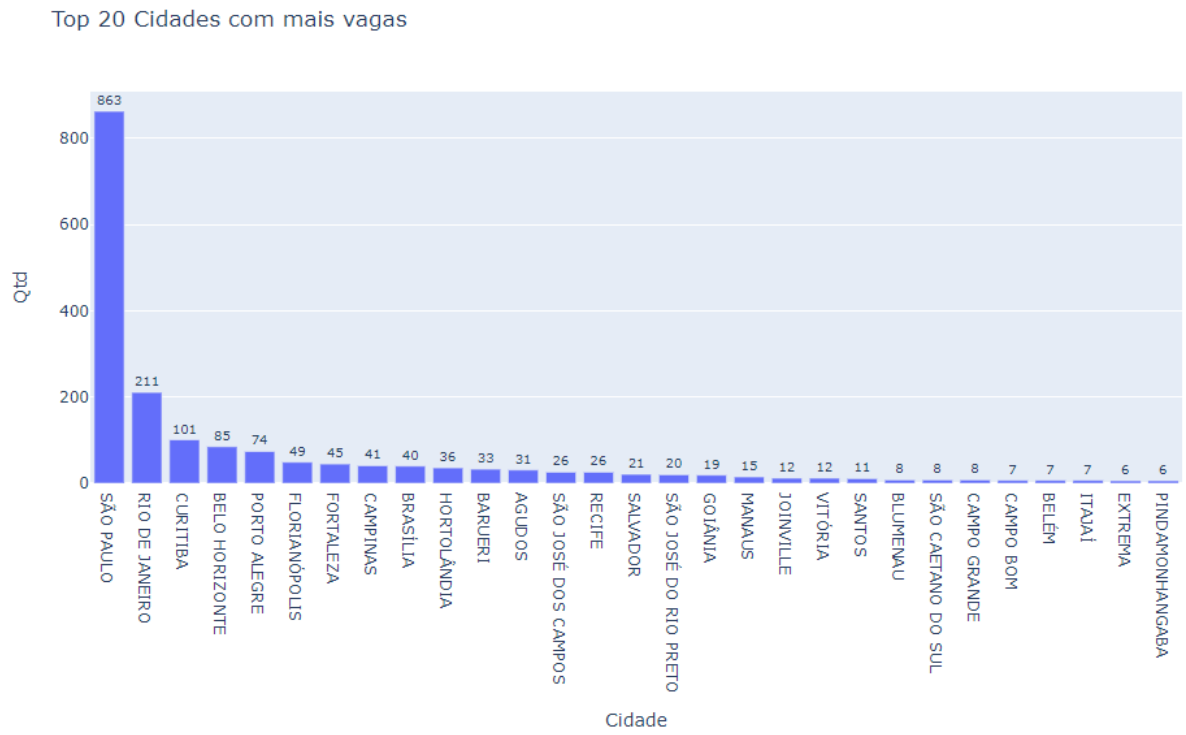


Figura 4. 20 cidades com mais vagas
Fonte: Resultados originais da pesquisa

Ao analisar o nível de senioridade das vagas, foi identificado que a informação de cargo nas vagas da plataforma muitas vezes não é preenchida ou é preenchida de forma incorreta. Isso pode ser percebido pois existem vagas com o campo de nível Assistente, por exemplo, mas com o título ou descrição especificando que o cargo é pleno ou sênior. Por isso, foi gerado um novo campo “position level” que verifica primeiramente se o nível está presente no título ou na descrição da vaga e, se não é utilizado o campo que vem da ferramenta. Mesmo com esse tratamento ainda restou uma quantidade considerável de vagas com nulos ou com cargo ‘Assistente’, o que não faz muito sentido. Desconsiderando os dados nulos, foi possível perceber que o nível júnior é muito mais representativo (29,14%) para a função de análise de dados que para as demais, enquanto o de pleno-sênior e sênior somam 38,45% para engenheiro de dados, enquanto para analista e cientista fica entre 15% e 17%. Uma hipótese é que a análise de dados é a porta de entrada para a área, enquanto a engenharia de dados é uma função que exige mais conhecimento técnico e consequentemente as empresas buscam por profissionais mais seniores. Muitos cargos como “tech lead” ou com uma senioridade alta como engenheiros de “machine learning” entraram na categoria outro, e por isso o número de vagas em níveis maiores também é significativo.

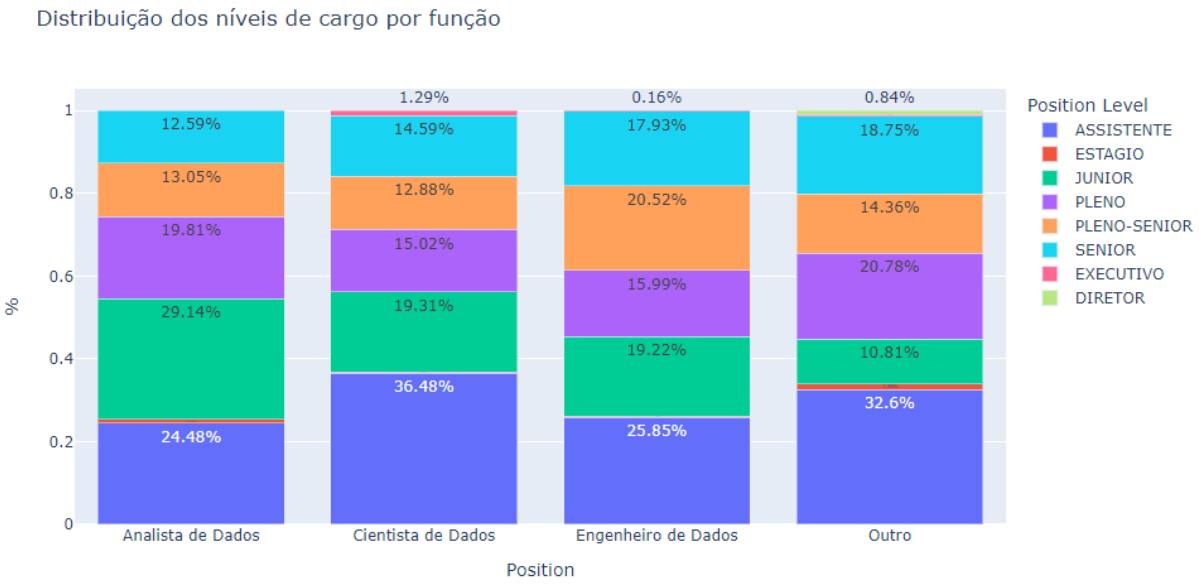


Figura 5. Distribuição dos níveis de senioridade por posição
Fonte: Resultados originais da pesquisa

A empresa que têm mais empregos disponíveis no período analisado é a IBM, com mais do dobro de vagas publicadas da segunda colocada.

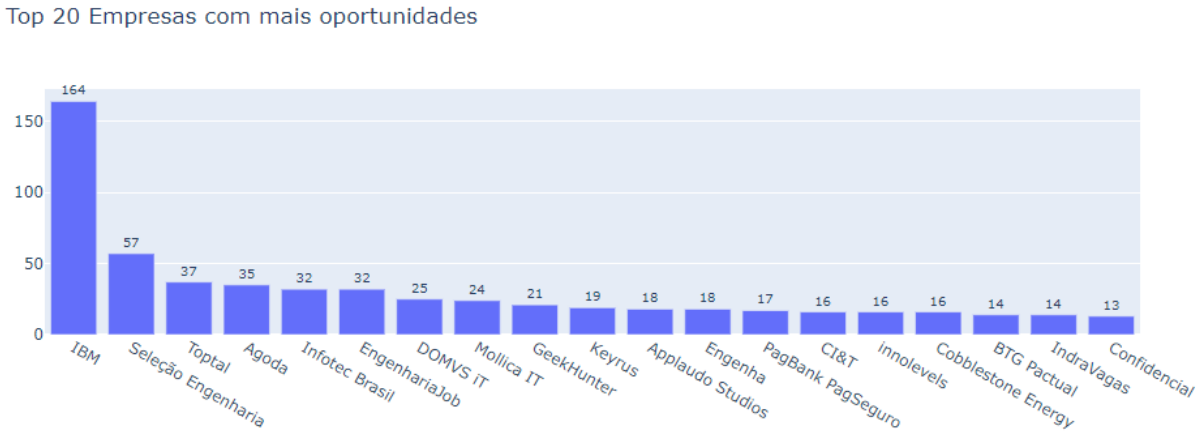


Figura 6. As 20 empresas com maior número de vagas
Fonte: Resultados originais da pesquisa

O setor de serviços e consultoria de TI é o que tem mais vagas abertas, o que é algo esperado, pois as consultorias de TI vêm crescendo bastante nos últimos anos. Em segundo lugar estão as empresas de recursos humanos, que são contratadas por empresas de segmentos diversos para buscarem profissionais qualificados no mercado.

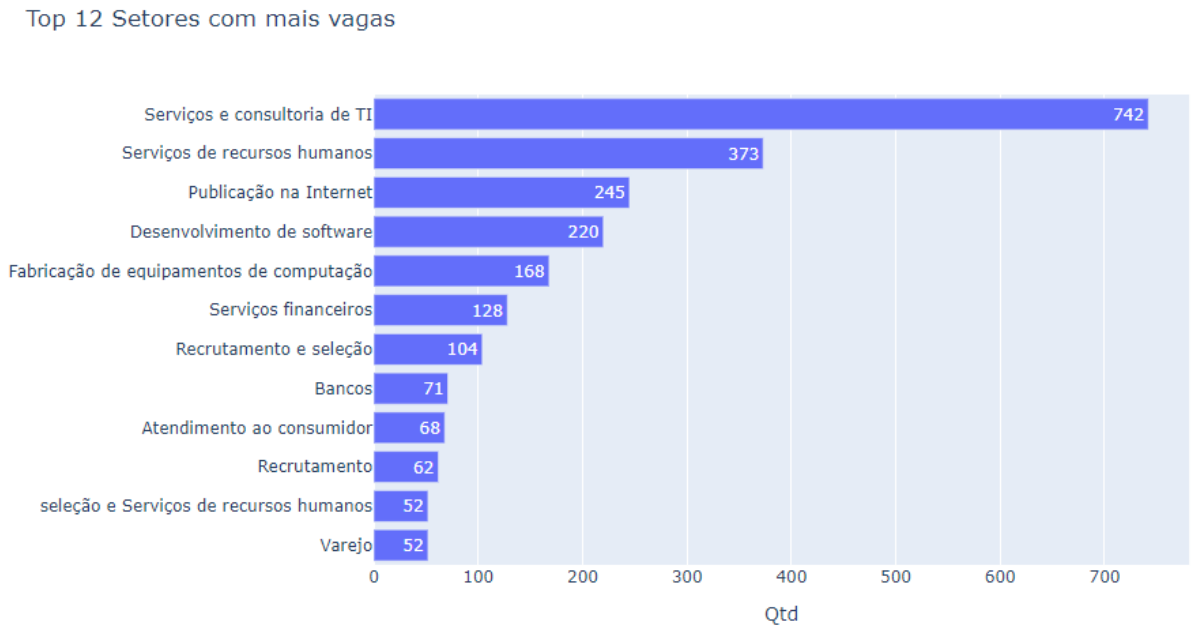


Figura 7. Os 12 setores com maior número de vagas
Fonte: Resultados originais da pesquisa

O tipo de trabalho e função não geraram informações relevantes.

Ao analisar as categorias criadas, como esperado, as categorias de Programação e Banco de Dados são as mais procuradas, tendo pelo menos uma das habilidades nelas listadas em mais de 65% das vagas. “Cloud”, “Dashboards” e Relatórios, Habilidades comportamentais e “Big Data” também tiveram uma presença significativa com valores próximos a 50%.

Tabela 1. Número de vagas e percentual sobre o total por Categoria

Categoria	Qtd	%
Programação	1785	71.46%
Banco de Dados	1669	66.81%
Cloud	1259	50.40%
Comportamental	1235	49.44%
Dashboards e Relatórios	1198	47.96%
Big Data	694	27.78%
Estatística	579	23.18%

Fonte: Resultados originais da pesquisa

Olhando para a distribuição de habilidades individualmente, as cinco mais procuradas são SQL, Python, Cloud, Excel e AWS. É possível perceber que o SQL e o Python tem uma

presença significativa para todas as posições. Somente para os analistas de dados que o Python não aparece em primeiro, ficando atrás do SQL e Power BI para essa função. Para engenheiro e cientista, o Python lidera e o SQL vem na sequência. Outro ponto que se destaca é que as habilidades Cloud, AWS, ETL, Spark, Scala, Java e Azure são maiores para engenheiro de dados, enquanto Power BI para o analista de dados e o R para cientista e analista de dados. Curiosamente, duas competências comportamentais, a comunicação e organização, estiveram entre as 15 competências mais procuradas, sugerindo que as empresas procuram profissionais que, além do conhecimento técnico, consigam se comunicar bem e sejam organizados.

Tabela 2. Número de vagas por Habilidades e Posição

Categoria	Habilidade	Analista de Dados	Engenheiro de Dados	Cientista de Dados	Outro	Total
Banco de Dados	Sql	384	654	175	275	1488
Programação	Python	252	667	262	230	1411
Cloud	Cloud	75	561	108	192	936
Dashboard e Relatórios	Excel	251	214	88	249	802
Cloud	Aws	84	402	79	156	721
Comportamental	Comunicação	166	206	103	222	697
Banco de Dados	Etl	110	436	47	45	638
Big Data	Spark	38	460	73	55	626
Dashboard e Relatórios	Power Bi	293	121	54	114	582
Programação	Scala	50	300	64	135	549
Programação	.Net	53	208	84	202	547
Comportamental	Organização	106	212	60	158	536
Programação	Java	50	237	36	163	486
Estatística	R	133	62	141	83	419
Cloud	Azure	36	242	47	77	402

Fonte: Resultados originais da pesquisa

Continuando a entender a existência de mais competências específicas de cada cargo, foi calculada a representatividade de cada habilidade dentro de cada posição, e para isso, foram necessários pesos diferentes, pois a quantidade de vagas retornadas nas pesquisas para cada posição foi diferente.

Na posição de analista de dados, o Power BI foi o que teve a maior diferença comparado as demais, com 61,95% contra 16,64%, 19,65% e 1,75%. Aparecem também Tableau e Qlik, que assim como o Power BI, são ferramentas de visualização de dados.

Tabela 3. Habilidades com maior delta para Analista de Dados em relação as demais

Habilidade	Analista_%	Engenheiro_%	Cientista_%	Outro_%
power bi	61.95%	16.64%	19.65%	1.75%
tableau	59.56%	17.89%	20.76%	1.78%
qlik	51.98%	27.77%	19.17%	1.08%
html	51.94%	12.99%	27.51%	7.56%
sql server	49.25%	35.19%	13.14%	2.42%

Fonte: Resultados originais da pesquisa

Engenheiro de dados representou 92,30% das vagas com o requisito HBase. Cassandra, ELT, Hive e “Data Warehouse” também fazem parte das habilidades mais requisitadas para engenheiros de dados. No geral, habilidades relacionadas a banco de dados e “big data” têm maior peso em funções de engenheiro.

Tabela 4. Habilidades com maior delta para Engenheiro de Dados em relação as demais

Habilidade	Analista_%	Engenheiro_%	Cientista_%	Outro_%	Total
hbase	2.76%	92.30%	4.74%	0.20%	1.197419
cassandra	11.73%	77.80%	8.08%	2.39%	1.064810
elt	19.56%	73.63%	5.32%	1.50%	1.149562
hive	7.74%	71.46%	20.43%	0.38%	1.335699
data warehouse	15.37%	69.16%	14.62%	0.85%	1.267120

Fonte: Resultados originais da pesquisa

No caso dos cientistas, habilidades relacionadas a estatística e pacotes de visualização se destacam. A maioria delas tem um delta em relação as outras de aproximadamente 80% para cientistas. Stata se destaca com 95,94% das oportunidades voltadas para essa posição.

Tabela 5. Habilidades com maior delta para Cientista de Dados em relação as demais

Habilidade	Analista_%	Engenheiro_%	Cientista_%	Outro_%
stata	0.00%	0.00%	95.94%	4.06%
plotly	6.77%	0.00%	93.23%	0.00%
regressão	7.15%	1.16%	90.72%	0.98%
probabilidade	6.48%	2.53%	89.29%	1.70%
matplotlib	5.76%	9.36%	84.25%	0.63%

Fonte: Resultados originais da pesquisa

Por fim, foram exploradas as habilidades de cada categoria. Para a categoria Banco de Dados, o gráfico acima mostra que o SQL é mais popular no geral. Do total de 2.498 vagas de emprego analisadas, 1.488 delas preferem que um candidato tenha conhecimento ou experiência com SQL.

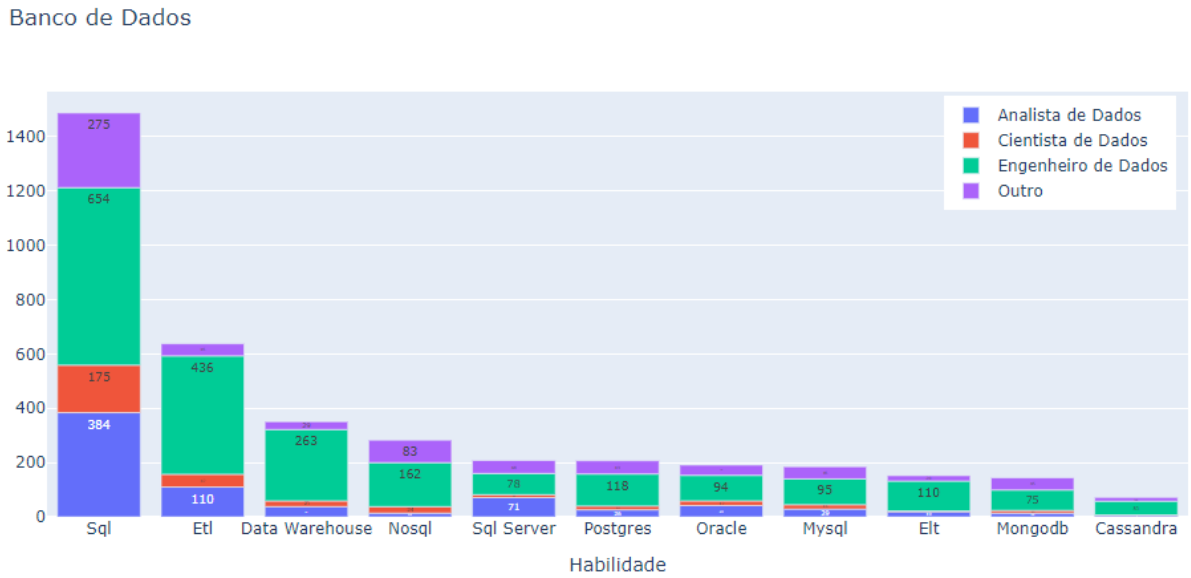


Figura 8. Habilidades mais procuradas da categoria banco de dados
Fonte: Resultados originais da pesquisa

A categoria de Programação também tem uma linguagem que se destaca, o Python, que aparece em 56,49% das vagas, com um total de 1.411, mais que o dobro da próxima linguagem, Scala, com 549. O R, que se encontra na categoria Estatística, também poderia estar nesta categoria e se estivesse ocuparia a quinta posição com 419, atrás de Java que foi encontrado em 486 vagas.

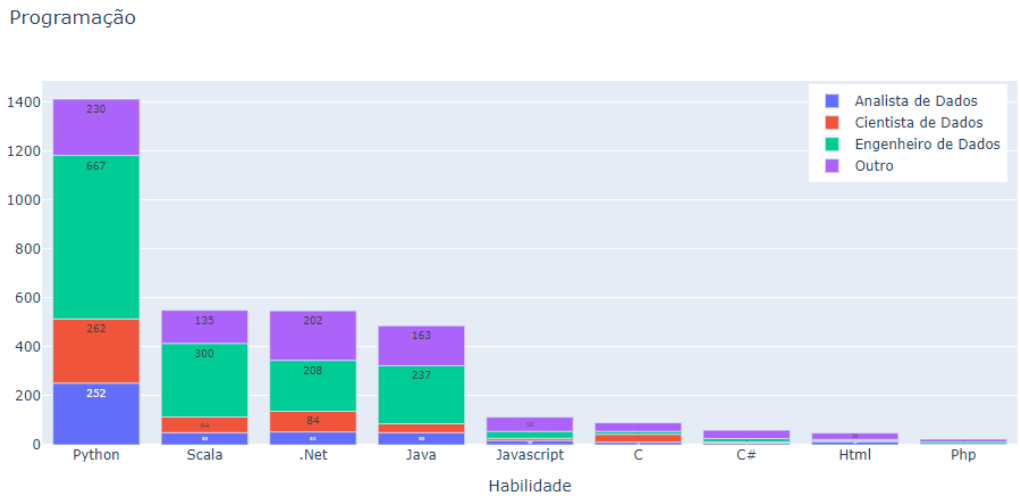


Figura 9. Habilidades mais procuradas da categoria programação
Fonte: Resultados originais da pesquisa

Para a categoria “cloud”, optou-se por analisar também a própria palavra, para verificar se a habilidade seria citada sem especificar qual a plataforma. Cloud aparece 936 vezes, enquanto as plataformas AWS, Azure e GCP 721, 402 e 320 respectivamente, refletindo o “market share” do mercado brasileiro de nuvem.

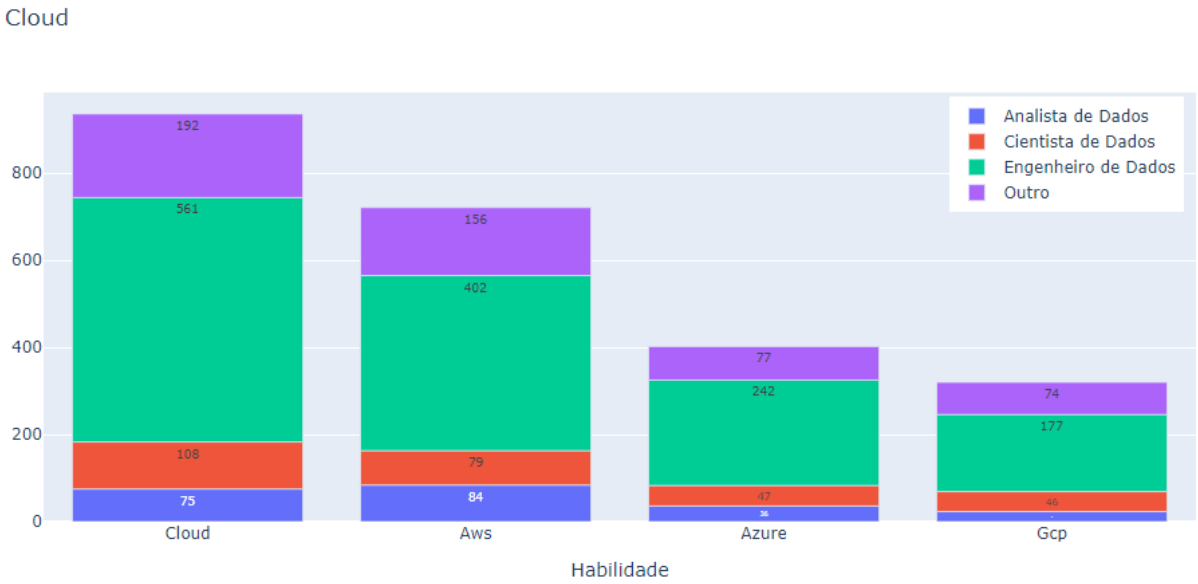


Figura 10. Habilidades mais procuradas da categoria cloud
Fonte: Resultados originais da pesquisa

Em Dashboards e Relatórios os mais populares são Excel, Power BI e Tableau, e como já esperado elas aparecem em maior quantidade para as posições de analista de dados. Elas aparecem também com alto volume para as posições ‘Outro’, o que provavelmente se deve as posições de analista de negócios, que geralmente exigem conhecimento em ferramentas de visualização e análise de dados, principalmente o Excel, que muitas vezes é a porta de entrada para essa área.

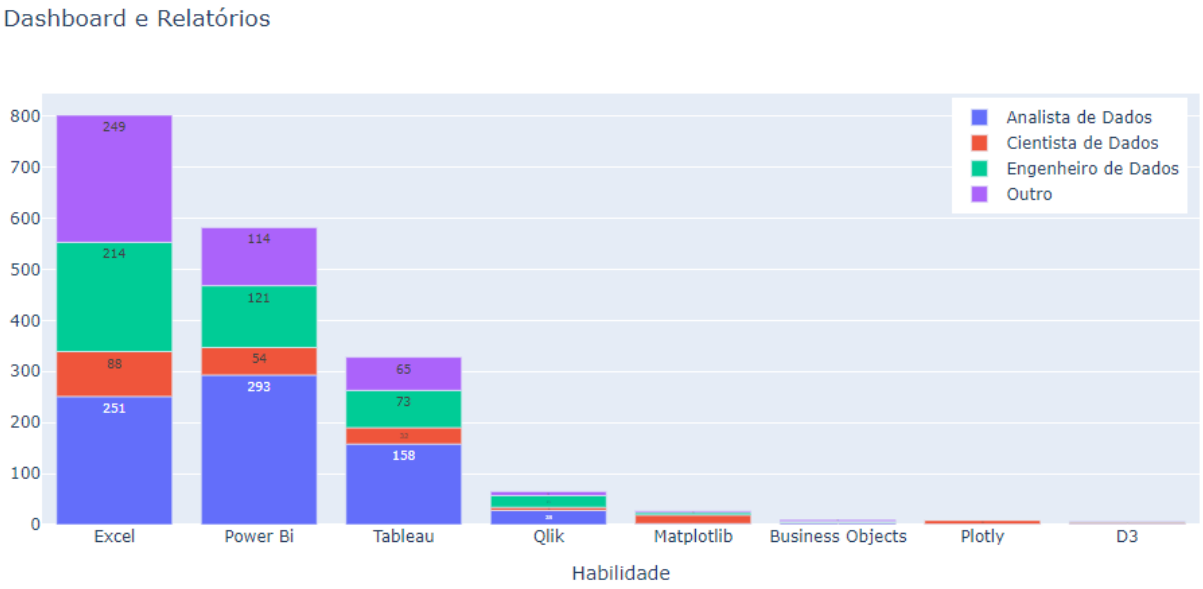


Figura 11. Habilidades mais procuradas da categoria dashboards e relatórios
Fonte: Resultados originais da pesquisa

Spark, Hadoop e Hive lideram nesta categoria, e essas habilidades são de longe mais requisitadas para engenheiros de dados.

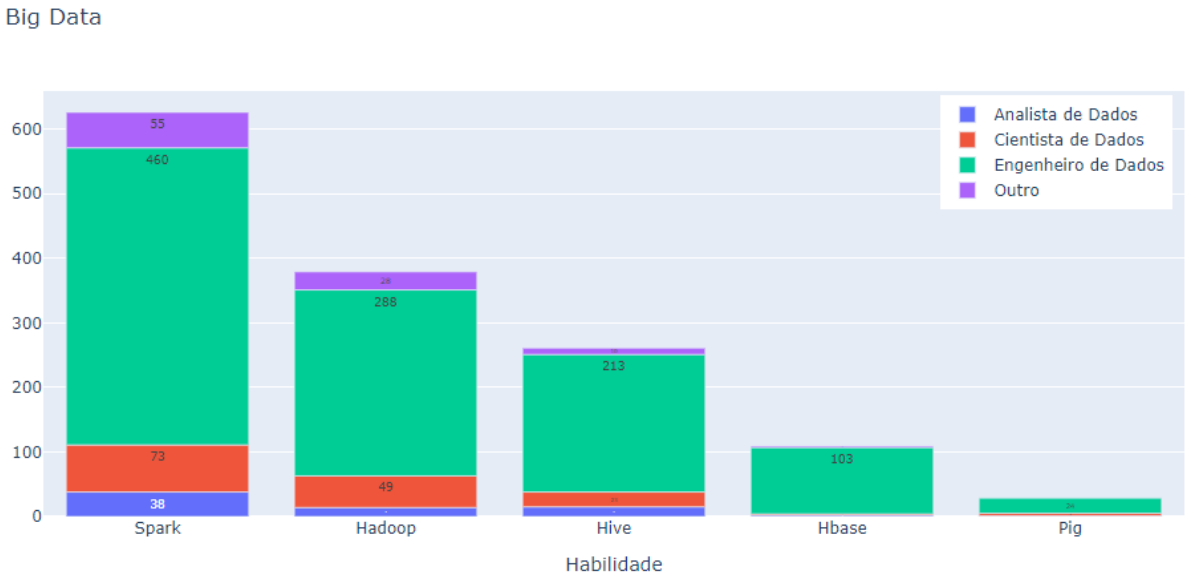


Figura 12. Habilidades mais procuradas da categoria big data
Fonte: Resultados originais da pesquisa

A Estatística, também incluída na análise, está entre as quatro mais populares, junto com R que liderou com 16,77%. Pandas, estatística e SAS ficaram com 6, 5,5 e 5%. Nesta categoria é possível perceber níveis maiores ou iguais de valores para cientistas de dados em relação as outras posições, o que não acontece em outras categorias, corroborando a importância da estatística para esses cargos.

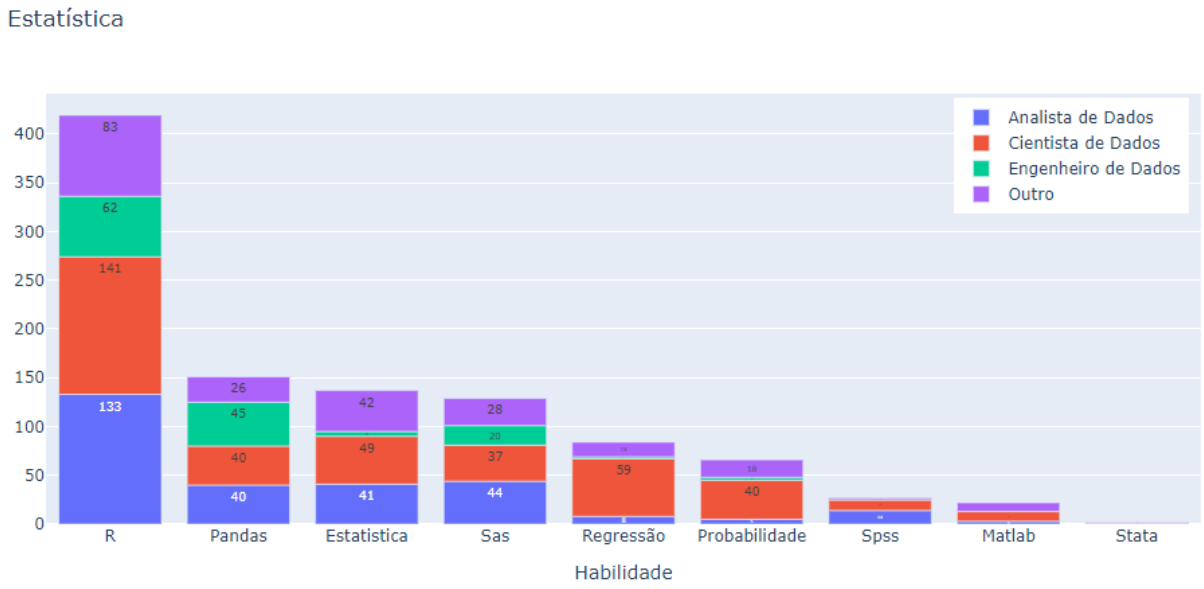


Figura 13. Habilidades mais procuradas da categoria estatística
Fonte: Resultados originais da pesquisa

Por fim, as habilidades comunicação e organização foram as mais populares entre as comportamentais.

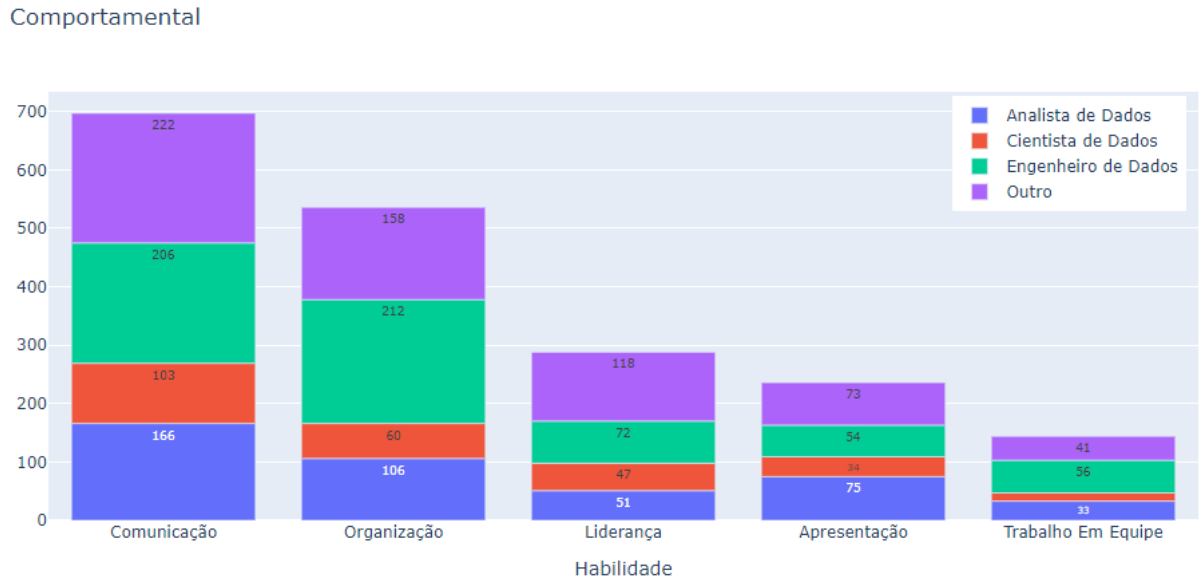


Figura 14. Habilidades mais procuradas da categoria habilidades comportamentais
Fonte: Resultados originais da pesquisa

Associação entre as habilidades

Para analisar a associação foram consideradas as 20 principais habilidades. É possível identificar correlações fortes positivas entre algumas delas. A maior é entre Hadoop e Spark, que são tecnologias diferentes, porém ambas são consideradas estruturas de “Big

Data". Na mesma linha, Spark e Python também tiveram fortes relações, mostrando que o Python é amplamente requerido em conjunto com o Spark. Power BI e Tableau tiveram a segunda maior associação e, por serem ferramentas análogas, gera a hipótese de que as empresas são flexíveis em relação a qual ferramenta de BI o candidato precisa ter experiência, então, pode-se concluir que é solicitado uma ou outra, e não procuradas em conjunto. A associação entre Python e SQL reafirma como é importante ter essas duas habilidades no mercado atual de dados. As altas correlações entre "cloud" e plataformas "cloud" como o GCP não é algo fora do esperado e que gere algum "insight". As demais associações são moderadas ou fracas.

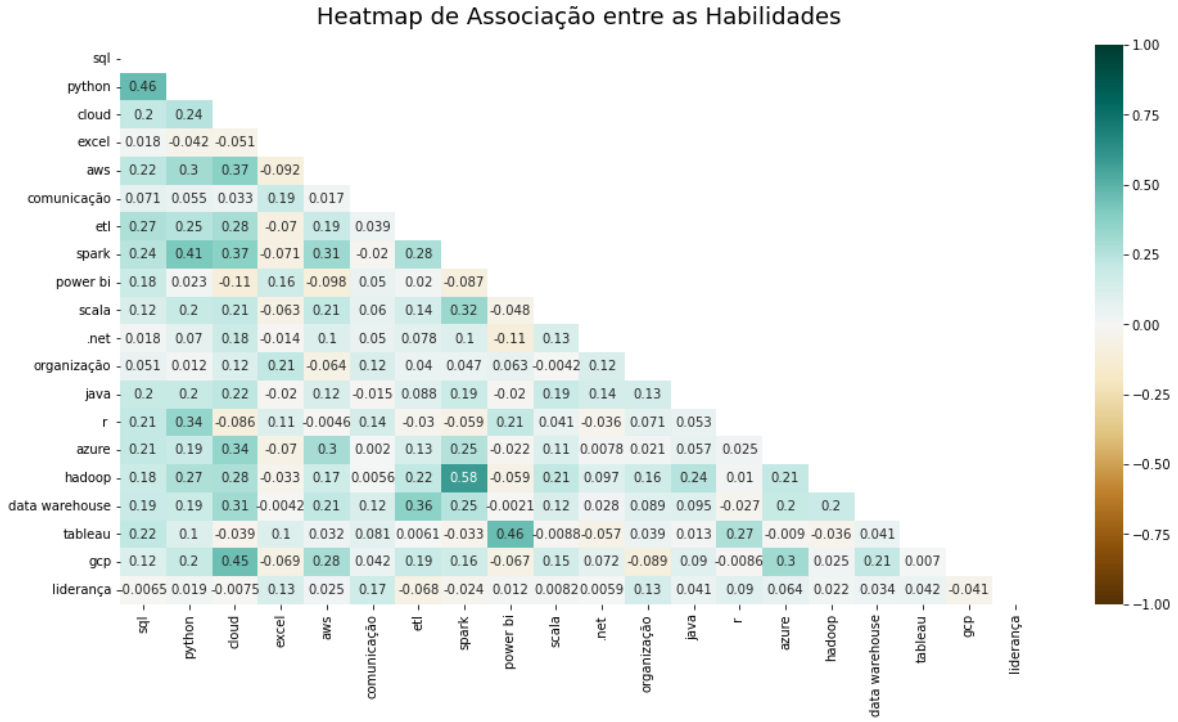


Figura 15. Heatmap da associação entre as habilidades mais procuradas
Fonte: Resultados originais da pesquisa

"Text mining"

Para não se limitar a analisar somente as habilidades pré-selecionadas, também foi realizado o processo de mineração de texto para buscar informações desconhecidas que podem ser úteis dentro dos textos das publicações. Para isso foi utilizada a biblioteca Tidytext para buscar os n-gramas, ou seja, a ocorrência de sequencias de palavras nos campos textuais título e descrição. Foram realizados alguns tratamentos como, colocar todas as palavras em letra minúscula, remover pontuações, caracteres especiais e remoção de

"stopwords" em inglês e português, que são palavras comuns aos idiomas que não agregam à análise, como por exemplo o, a, em e no.

Os unigramas dos títulos das vagas, que são as principais palavras individuais encontradas, estão representados visualmente na nuvem de palavras da figura 16, que dá maior destaque às palavras que aparecem com mais frequência. No geral as que ficaram em maior destaque são as palavras dados, engenheiro, analista, cientista e suas variações em inglês. Isso mostra a importância de considerar também palavras nesse idioma para buscar vagas.



Figura 16. Nuvem de palavras dos títulos das vagas
Fonte: Resultados originais da pesquisa

Os bigramas e trigramas mostram quais são as combinações de duas e três palavras, respectivamente, mais frequentes no texto. A maioria das combinações no título da vaga foram dos cargos que tiveram maior enfoque neste trabalho, que são de analistas, cientistas e engenheiros de dados e os respectivos níveis, com exceção de "big data" e "business intelligence", que são variações das nomenclaturas dos cargos de dados e também se mostram relevantes.

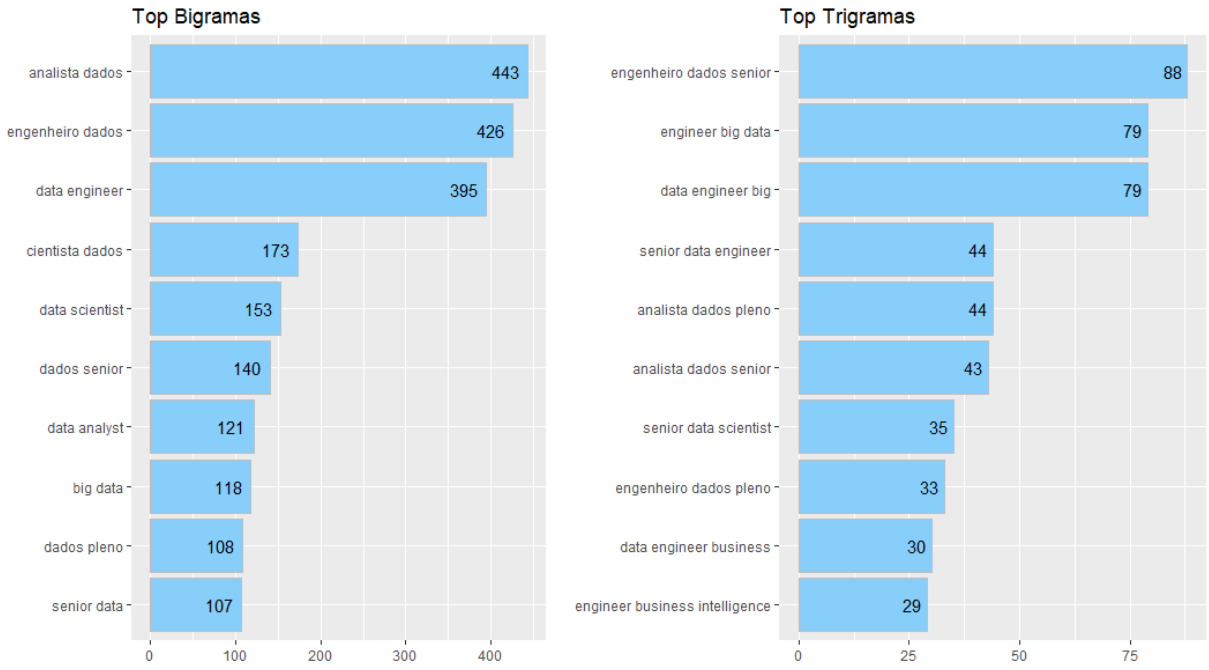


Figura 17. Principais bigramas e trigramas nos títulos das vagas
Fonte: Resultados originais da pesquisa

Na nuvem de palavras da descrição foi possível encontrar as habilidades identificas no trabalho como as mais requisitadas, o Python e o SQL. Time, “business”, pessoas, clientes, requisitos, processos e projetos são alguns exemplos que mostram a importância desses profissionais também terem habilidades em processos e projetos, além de habilidades interpessoais para relacionamento com pessoas, equipe e clientes.



Figura 18. Nuvem de palavras das descrições das vagas
Fonte: Resultados originais da pesquisa

Para análise de cada posição separadamente, foi utilizado apenas o campo descrição, pois gerou informações mais relevantes.

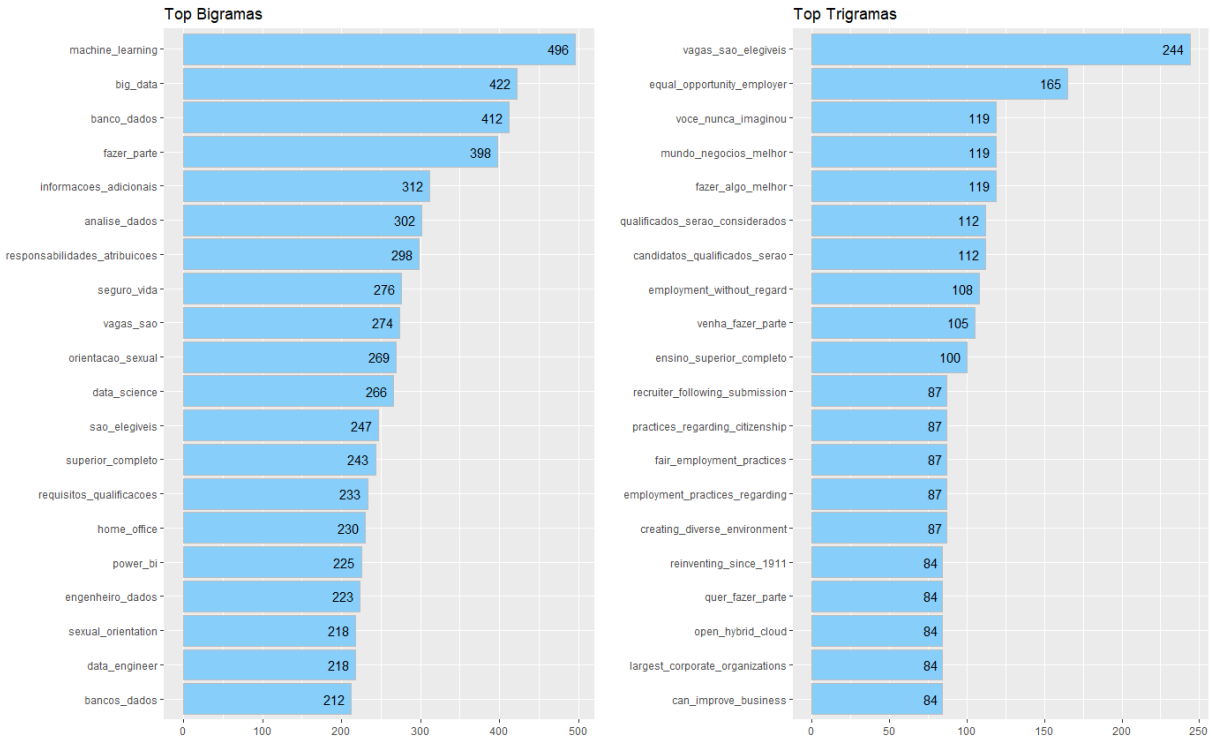


Figura 19. Principais bigramas e trigramas nas descrições das vagas
Fonte: Resultados originais da pesquisa

Achou-se oportuno gerar também uma análise dos n-gramas das descrições das vagas para cada posição separadamente. Os trigramas não retornaram informações interessantes e por esse motivo não foram considerados.

Para analistas de dados fica em evidência as habilidades técnicas de análise e visualização como Power BI, dashboards, SQL, corroborando as descobertas anteriores.

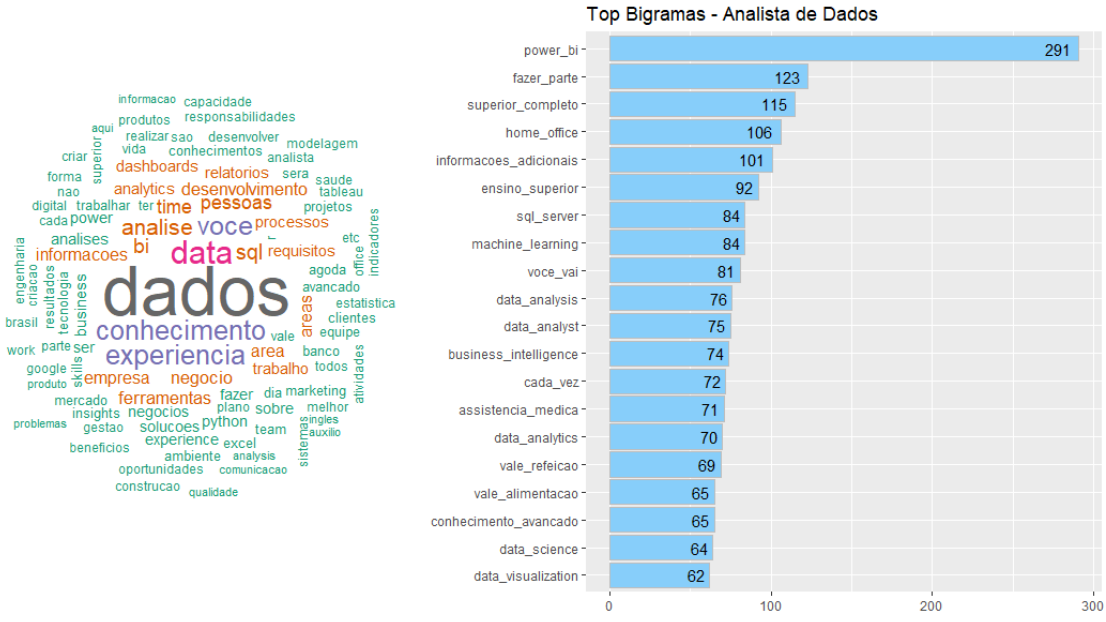


Figura 20. Principais unigramas e bigramas nas vagas de Analista de Dados
Fonte: Resultados originais da pesquisa

"Machine learning", "data science", big data, inteligência artificial, "deep learning", modelos estatísticos e preditivos são algumas das combinações de palavras que tem maior ênfase nas oportunidades para cientista de dados.

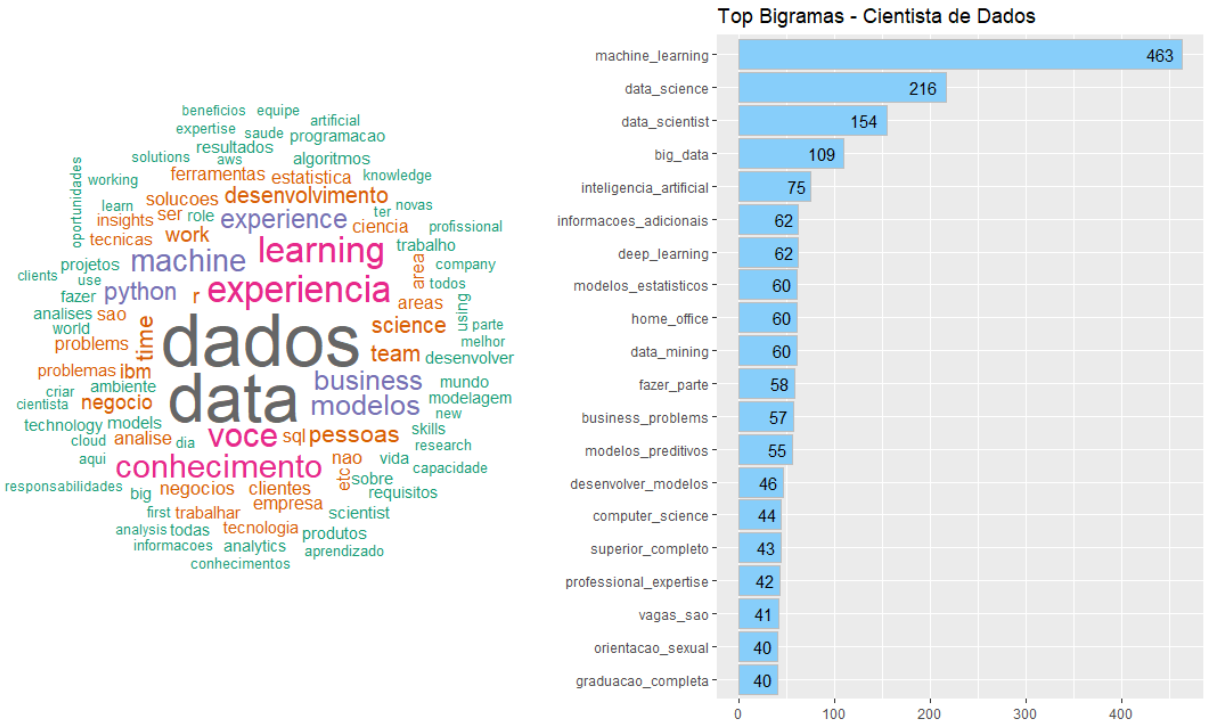


Figura 21. Principais unigramas e bigramas nas vagas de Cientista de Dados
Fonte: Resultados originais da pesquisa

Os termos que realçam nas vagas para engenheiro de dados são "big data", "data lake", "data warehouse", "data pipeline" e também algumas relacionadas a "cloud".

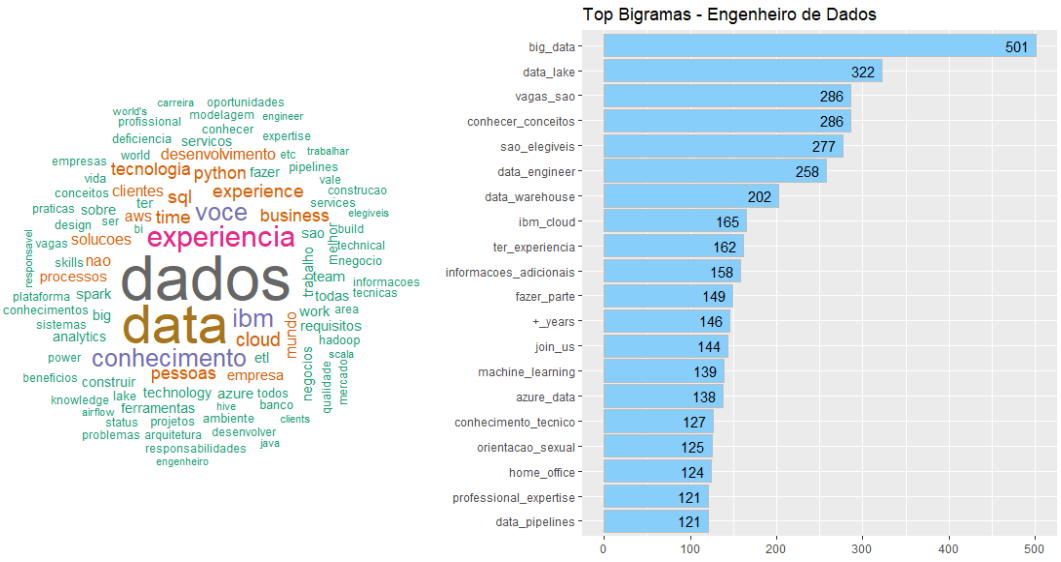


Figura 22. Principais unigramas e bigramas nas vagas de Engenheiro de Dados
Fonte: Resultados originais da pesquisa

Considerações Finais

Utilizando uma amostra de vagas de empregos do LinkedIn, este estudo ajuda a esclarecer quais habilidades as organizações estão buscando para cada perfil da área de análise de dados. A análise mostra que todas as categorias de conhecimento criadas são necessárias, mas algumas são mais direcionadas para funções específicas, como por exemplo cloud e big data para engenheiro de dados. Além das habilidades técnicas, as competências comportamentais também são cruciais e demandadas em todas as posições. Existem também habilidades chave, como Python e SQL, que são unanimidade em todas as carreiras e podem ser priorizadas no aprendizado de profissionais e estudantes que almejam uma carreira na área.

Referências

Chicco, D.; Jurman, G. 2020. The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation. BMC Genomics. 21, 6.

Dubey, R.; Gunasekaran, A. 2015. Education and training for successful career in big data and business analytics. Industrial and Commercial Training, 47(4), 174–181.

Fayyad, U.; Hamutcu, H. 2020. Toward Foundations for Data Science and Analytics: A Knowledge Framework for Professional Standards. Harvard Data Science Review, 2(2).

LinkedIn. 2020. Emerging Jobs Report Brazil. Disponível em: <https://business.linkedin.com/content/dam/me/business/en-us/talent-solutions/emerging-jobs-report/Emerging_Jobs_Report_Brazil.pdf>. Acesso em: 10 mar. 2022.

Pellaes, A. 2021. A adoção de ferramentas de atração e recrutamento online pelas organizações no brasil: um estudo sobre motivações e impactos.

Reis, E. A.; Reis, I. A. 2002. Análise Descritiva de Dados. Relatório Técnico do Departamento de Estatística da UFMG.

Schonlau M.; Guenther N.; Sucholutsky I. 2017. Text Mining with n-gram Variables. The Stata Journal.;17(4):866-881. doi:10.1177/1536867X1801700406

Verma, A.; Yurov, K.; Lane, P.; Yurova, Y. 2019. An investigation of skill requirements for business and data analytics positions: A content analysis of job advertisements. Journal of Education for Business. 94. 1-8. 10.1080/08832323.2018.1520685.

Zhao, B. 2017. Web scraping. Encyclopedia of big data, 1-3.