A acurácia dos modelos “boosting de machine learning” no mercado brasileiro de ações

José Erasmo Silva[1]*; Renato Máximo Sátiro[2]

[1] Doutor em administração. Rua Bom Jesus, 1031 – Bairro Alto; 13419-055 Piracicaba, São Paulo, Brasil
[2] Escola Superior de Agricultura "Luiz de Queiroz" - USP/ESALQ. Professor do curso de MBA em Data Science e Analytics. Rua Alexandre Herculano 120, sala T4 – Vila Monteiro; 13418-445 Piracicaba, São Paulo, Brasil
Universidade Federal de Goiás - UFG. Doutor em Administração pelo Programa de Pós-Graduação em Administração. Avenida Esperança s/n - “campus” Samambaia - Prédio da Reitoria. 74690-900 Goiânia, Goiás, Brasil
*autor correspondente: jose.erasmo@natelcontact.com.br

A acurácia dos modelos “boosting de machine learning” no mercado brasileiro de ações

Resumo

O mercado de ações está entre os pilares mais abrangentes e importantes da economia de qualquer país, pois desempenha um papel crucial em seu processo de crescimento e, ao longo do tempo, alimenta a força de trabalho econômica. A previsão do retorno de ações é uma relevante área de pesquisa e tem atraído muita atenção de pesquisadores e investidores em virtude do potencial de benefícios monetários decorrentes dessa previsão. O objetivo deste estudo foi verificar a acurácia dos algoritmos CatBoost, “gradient boosting”, AdaBoost, LightGBM e XGBoost na previsão de retornos mensais de ações no mercado brasileiro. Os modelos foram treinados e avaliados no período de 2017 a 2021, e o que se destacou como mais eficiente sob a perspectiva da maioria das métricas foi o CatBoost, o qual, entre os algoritmos apresentados, é um dos mais promissores e sofisticados derivados das árvores de decisão.

Palavras-chave: mercado de ações; modelos de previsão; CatBoost.

The accuracy of machine learning boosting models in the Brazilian stock market

Abstract

The stock market is among the most comprehensive and important pillars of any country's economy for its crucial role in its growth process over time feeding the economic labor force. Forecasting stock returns is a relevant research area that has attracted much attention from researchers and investors due to its potential monetary benefits. This study aims to verify the accuracy of the CatBoost, gradient boosting, AdaBoost, LightGBM, and XGBoost algorithms in forecasting monthly stock returns in the Brazilian market. The models were trained and evaluated in the period from 2017 to 2021, with CatBoost as standing out as the most efficient from the perspective of most metrics, being one of the most promising and sophisticated derived algorithms from decision trees.

Keywords: stock market; forecasting models; CatBoost.

Introdução

O mercado de capitais é visto como uma peça de grande importância no desenvolvimento dos países, pois contribui para as indústrias de maneira geral, as quais, por sua vez, fomentam a força de trabalho econômica (Ghashami e Kamyar, 2021).

A previsão do retorno de ações é um pertinente campo de pesquisa e tem atraído considerável atenção de pesquisadores e investidores devido ao potencial de benefícios monetários decorrente dessa previsão. O desenvolvimento de um modelo adequado e a seleção de características representativas do fenômeno em estudo são partes fundamentais de uma previsão acurada (Haq et al., 2021).

Nessa perspectiva, destaca-se que a previsibilidade dos retornos no mercado de ações é um dos mais controversos assuntos em finanças. Apesar de economistas, estatísticos, investidores e pesquisadores se preocuparem em melhorar ou criar novos

modelos de previsão, ainda não há consenso entre eles se isso é possível (Elmsili e Outtaj, 2021).

Ainda nesse sentido, observa-se que a ideia da imprevisibilidade do mercado de ações é suportada pela hipótese dos mercados eficientes, que é um dos pilares da teoria clássica de finanças, e foi proposta por Fama em 1970 (Fama, 1998). Tal hipótese assume que os preços de uma ação incorporam todas as informações disponíveis e são baseados nas expectativas racionais dos investidores que buscam aumentar seus lucros. No entanto, no mundo real, investidores usam diferentes estratégias para tomadas de decisão e interpretam de forma heterogênea as informações disponíveis (Ben Abdelaziz e Mrad, 2021).

As abordagens de previsão do retorno de ações são categorizadas em análise fundamentalista e análise técnica de acordo com o tipo de informação que cada uma delas utiliza. Na análise fundamentalista, investidores estimam o preço intrínseco de uma ação examinando vendas, lucros, dívidas e dividendos da empresa. Por outro lado, a análise técnica avalia as ações observando tendências e estatísticas geradas pela atividade do mercado, como preços históricos e volume de negócios (Haq et al., 2021; Rajkar et al., 2021; Xu et al., 2021).

A previsão de retorno pode ainda ser vista sob outra perspectiva, em que são empregados métodos de “machine learning” no processo de análise e de tomada de decisão, os quais utilizam algoritmos, entre eles: “Support Vector Machines [SVM]”, “Recurrent Neural Network [RNN]” e “Extreme Learning Machine [EML]”, desenvolvidos por cientistas da computação e que visam avaliar e conduzir a descoberta de informações em larga escala em um curto período (Rajkar et al., 2021). Vale destacar que a maioria desses algoritmos utiliza como base as informações de preços dos ativos e a análise técnica (Xu et al., 2021).

Com o rápido desenvolvimento do “machine learning”, tais algoritmos vêm sendo amplamente utilizados na solução de vários problemas práticos das indústrias. Mais recentemente, pesquisadores têm se dedicado a estudar e a aplicar esses mesmos algoritmos para previsões no mercado de ações, o que tem proporcionado melhores investimentos (Liu et al., 2021).

Apesar de não ser um assunto novo, os sistemas baseados em “machine learning” vêm despertando cada vez mais interesse de tomadores de decisão nos últimos anos, devido à sua habilidade de entregar o estado da arte em uma variedade de domínios, por exemplo, visão de computador, entendimento de linguagem natural e reconhecimento de fala. Assim como em outras áreas, na literatura financeira, apesar da crença dos mercados eficientes, essas ferramentas também têm sido testadas (Elmsili e Outtaj, 2021).

Com o número crescente de investidores registrados na bolsa de valores, que saltou de 1 milhão, em 2019, para 3,8 milhões, em junho de 2021, nota-se cada vez mais a

preocupação dos brasileiros, especialmente os mais jovens, em buscar novas fontes de rendimentos por meio do mercado financeiro (B3, 2021).

Guerard et al. (2019) destacam a necessidade de constante avaliação dos modelos de investimento, pois ninguém pode testar somente um algoritmo ou método e investir dinheiro a partir dele. Dessa forma, novos modelos e reavaliações dos antigos são importantes, tendo em vista que o comportamento do mercado está em contínua transformação, principalmente em virtude de novos investidores, empresas, governos e até mesmo novas leis.

Posta a necessidade de avaliação e de criação de modelos de investimento e, levando ainda em conta o crescente interesse pelo investimento em ações, dada a possibilidade de maiores retornos desde que se assumam maiores riscos, o trabalho pretende proporcionar a pequenos investidores “insights” sobre quais ferramentas de “machine learning” podem ser utilizadas na análise de ações. Nesse sentido, o presente estudo tem como objetivo verificar a acurácia dos principais e mais atuais algoritmos de “machine learning” na previsão de retornos mensais no mercado de ações brasileiro.

Material e Métodos

Os dados para o estudo foram coletados através da plataforma Economatica e processados para obtenção dos resultados utilizando a linguagem Python. Foram utilizadas como amostra as informações mensais ajustadas dos preços de fechamento de todas as empresas listadas na B3 referentes ao período de 2017 a 2021, coletadas através da plataforma Economatica. Como critério de filtragem de ações de baixa liquidez, selecionou-se somente as ações com negociação em todos os dias no período de treino e teste. Nesses moldes, 250 empresas foram testadas nos modelos que geraram 14.640 registros. Ressalta-se que nem todas as empresas estiveram em todos os períodos de treino e teste.

Depois de definida a amostra, é muito comum a discussão sobre eliminar ou não os “outliers”. No contexto deste trabalho, optou-se por eliminá-los quando estivessem fora do patamar comum do mercado e que geralmente se caracterizam por erros. Desse modo, os retornos das ações foram classificados em percentis e foram eliminadas as ações cujos retornos se enquadrassem nos percentis 1 e 99.

Após a eliminação dos “outliers”, foi executado o processo de engenharia de características ("feature engineer"), o qual consiste em criar os indicadores que serão utilizados como variáveis explicativas no modelo a partir das informações coletadas das quatro cotações (de abertura, máxima, mínima e de fechamento) e do volume e de negócios. A acurácia nas previsões é função principalmente da seleção de indicadores representativos

e do desenvolvimento de um modelo apropriado (Haq et al., 2021). A Tabela 1 apresenta as referidas variáveis.

Tabela 1. Variáveis explicativas

Variável	Descrição
Retorno	Retorno de 1, 2, 3, 6, 9 e 12 meses
Retornos defasados	Referentes ao 1º, 2º, 3º, 4º, 5º e 6º mês
“Momentum”	Referente a 2, 3, 6, 9 e 12 meses
Ano	Ano referente aos dados
Mês	Mês referente aos dados

Fonte: Dados originais da pesquisa

Após o tratamento dos dados e a criação dos indicadores técnicos, foram utilizadas as abordagens “boosting” em árvores de decisão para atingir o objetivo do presente estudo, isto é, verificar a acurácia dessas abordagens na previsão de retornos mensais positivos no mercado de ações brasileiro. Para representar a variável dependente, os retornos foram transformados em uma variável binária que recebeu 1 para retorno positivo e 0 para retorno negativo.

Árvore de decisão é o modelo de classificação mais utilizado em conjuntos de aprendizagem. A ideia básica dessa ferramenta é a seguinte: primeiramente, em cada nó, a árvore é baseada em múltiplas regras de recursos, e a seleção de variáveis e de valores de variáveis é realizada de acordo com o desempenho do efeito de classificação. Na sequência, com base nas variáveis selecionadas, após dividir a área dos dados, compara-se o efeito da classificação e a complexidade do modelo, determina-se o método de divisão ideal, divide-se o próximo nó da folha até que o nó não possa mais ser dividido e toma-se decisões de classificação (Chen et al., 2020). Apesar das árvores de decisão ainda serem utilizadas em alguns estudos, elas têm caído em desuso devido ao surgimento de modelos que combinam essas árvores para obter resultados mais consistentes, são os chamados “ensemble models”.

No contexto do “ensemble” parte-se da premissa que os resultados em conjunto são melhores que os resultados individuais. Apesar de envolver alguns perigos no sentido de propagar-se erros através de vários modelos, de maneira geral os modelos ensemble apresentam melhores resultados que os modelos individuais (Nabipour et al., 2020).

Entre os ensembles mais famosos estão os “baggings” e os “boostings”. A principal diferença entre eles é que o bagging trabalha com um conjunto de árvores em paralelo e o resultado geral é dado pela média dos resultados das árvores. Os modelos boosting trabalham com árvores sequenciais no qual o objetivo de cada árvore é melhorar o resultado da árvore anterior. Tendo em vista que os modelos boosting tem uma amplitude maior de modelos bem como tem apresentado melhores resultados e frequentes implementações, optou-se no presente estudo por explorar somente esse grupo.

O método “boosting” é um dos mais poderosos conceitos de aprendizado de máquina introduzidas nos últimos 30 anos. O primeiro modelo de “boosting” foi desenvolvido por Robert Schapire e Yoav Freund por volta de 1990 (Jansen, 2020). A ideia principal baseia-se na possibilidade de se construir um modelo “forte” a partir da combinação de vários modelos “fracos” (Hastie et al., 2009). Ou seja, a motivação por trás do “boosting” foi encontrar um método que combina os resultados de muitos modelos fracos, em que “fraco” significa um desempenho apenas ligeiramente melhor do que um palpite aleatório em uma previsão conjunta altamente precisa (Schapire e Freund, 2013).

De maneira geral, o “boosting” aprende uma hipótese aditiva, H_M, de forma similar com uma regressão linear. No entanto, cada um dos m=1,...,M elementos de uma somatória é um aprendiz fraco, chamado de h_t, que por si só requer treinamento (Jansen, 2020). A form. (1) sumariza essa abordagem.

$$H_M(x) = \sum_{m=1}^{M} h_t(x) \quad (1)$$

onde, $h_t(x)$: são os aprendizes fracos.

A partir desse conceito central, outros algoritmos surgiram como extensões, sendo que o mais popular é chamado de “adaptive boosting”, ou “AdaBoost”, e foi criado por Freund e Schapire (1997). É um algoritmo iterativo que treina diferentes subclassificadores para o mesmo conjunto de dados, de modo específico treina continuamente os dados classificados erroneamente e então serializa esses classificadores fracos para formar um classificador forte (Chen et al., 2020; Hastie et al., 2009). Um dos pontos a se destacar a respeito desse modelo é que ele faz ponderações nos erros e acertos de forma que os erros sejam mais trabalhados nas etapas posteriores do algoritmo.

Em 1999, Jerome Friedman criou o “gradient boosting”, modelo que tem produzido o estado da arte em termos de desempenho tanto em classificações quanto em regressões. Ele é provavelmente o mais popular em competições de “machine learning”, além de ser utilizado em aplicações do mercado, por exemplo, para prever taxas de cliques em anúncios “on-line” (Jansen, 2020).

O “gradient boosting” aplica uma abordagem diferente do AdaBoost. Nesse sentido, também se ajusta baseado nas previsões incorretas, porém leva essa ideia a um passo adiante, ou seja, se ajusta a cada nova árvore inteiramente fundamentado nos erros das previsões da árvore anterior. Em outras palavras, para cada árvore, ele analisa os erros e

constrói uma nova árvore completamente em torno desses erros, a qual não leva em consideração as previsões que já estão corretas (Wade, 2020).

Nos últimos anos, muitas implementações de “gradient boosting” passaram a utilizar inovações que aceleram o treinamento dos modelos ou dos algoritmos, melhoram a eficiência dos recursos e permitem que o algoritmo seja dimensionado para conjuntos de dados muito grandes. Entre elas, estão os algoritmos “Extreme Gradient Boosting [XGBoost]”, “Light Gradient Boosting Machine [LightGBM]” e “Categorical Boosting [CatBoost]” (Jansen, 2020).

O XGBoost foi iniciado, em 2014, por Tianqi Chen em seu processo de doutorado e ganhou muita popularidade: entre as 29 soluções vencedoras publicadas pelo Kaggle – plataforma em que se pode participar de competições de algoritmos e também trocar ideias, códigos, compartilhar dados –, em 2015, 17 usaram XGBoost, sendo que 8 delas o empregaram isoladamente, e o restante combinou com outros algoritmos (Chen e Guestrin, 2016). Atualmente, ele tem sido utilizado em várias áreas, tal como energia, assistência média e “score” de crédito (Jabeur et al., 2021; Mo et al., 2019). A fórmula de saída é calculada com a form. (2):

$$yhat_i^T = \sum_{k=1}^{T} f_k(x_i) = yhat_i^{T-1} + f_T(x_i) \quad (2)$$

onde, $yhat_i^{T-1}$: é a árvore de decisão gerada; $f_T(x_i)$: é o modelo de árvore recém-criado; e T: é o total de árvores no modelo. De maneira geral, as principais vantagens do XGBoost em relação as implementações anteriores são: 1) Possibilidade de utilização de computação paralela; 2) Utilização de matrizes esparsas; 3) Alocação dos dados em blocos. Tudo isso proporcionou ganhos em precisão e desempenho.

O LightGBM foi criado pela Microsoft e liberado para uso público em janeiro de 2017 (Ke et al., 2017). Muitos estudos mostraram que esse algoritmo é mais eficiente e possui maior acurácia que os modelos anteriores, principalmente no sentido de consumo de memória e velocidade de treinamento (Jabeur et al., 2021). É um dos mais avançados algoritmos de elevação gradiente. O modelo usa estes métodos: aprimoramento gradiente integrado para melhorar a robustez do classificador; árvore de decisão com profundidade limitada para evitar o ajuste excessivo (“overfitting”); amostragem unilateral baseada em gradiente para representar a importância das instâncias de dados; algoritmo de histograma para encontrar a melhor divisão (Yin et al., 2021). Segundo Jabeur et al. (2021), a função estimada do LightGBM integra várias árvores de regressão T e é definida da seguinte forma (form. 3):

$$Y_t = \sum_{h=1}^{T} f_t(x) \quad (3)$$

onde, $f_t(x)$: denota a árvore de regressão. No LightGBM, o método de Newton foi usado para estimar a função objetivo. As principais inovações dessa implementação em relação aos anteriores são: 1) Usa um método chamado “gradiente-based one-side sampling” para excluir uma parte significativa da amostra que é pouco significativa para os resultados; 2) Usa um pacote de recursos exclusivos para combinar recursos que são mutuamente exclusivos; 3) Prioriza as quebras das árvores de maneira diferenciada.

Por fim, o CatBoost foi criado pela empresa Yandex e liberado para uso público em abril de 2017 (Prokhorenkova et al., 2018). Assim como os modelos anteriores, esse algoritmo também utiliza o “gradient boosting” em árvores de decisão. Uma das vantagens que o CatBoost e o LightGBM têm sobre os demais modelos é que não há necessidade de transformar as variáveis categóricas em “dummies”, pois ambos lidam com elas diretamente. Nesse sentido, o CatBoost pode combinar diferentes categorias para criar novas categorias (Jansen, 2020).

Ainda a respeito do CatBoost, é importante salientar que ele resolveu um problema conhecido como “missing target”, que é encontrado nos algoritmos XGBoost e LightGBM. Tal problema faz com que as previsões feitas por esse modelo dependam de todos os “targets” utilizados no treinamento e, caso haja mudanças na amostra, os resultados das previsões ficam comprometidos (Xu et al., 2021). Além disso, o CatBoost tem uma versão que utiliza “Graphics Processing Units [GPU]” e aumenta significativamente a velocidade de treinamento. De acordo com Jabeur et al. (2021), a função h da árvore de decisão do modelo pode ser escrita com a form. (4):

$$h^t \arg\min \frac{1}{N} \sum \left(-f^t(X_k, Y_k) - h(X_k)\right)^2 \quad (4)$$

onde, X_k: é um vetor aleatório de N variáveis de entrada; Y_k: é a saída; e f: é uma aproximação de mínimos quadrados pelo método de Newton.

Para Sun et al. (2020), a acurácia dos modelos depende fortemente dos hiperparâmetros selecionados para cada um deles. Portanto, antes de executar cada modelo, deve-se definir quais configurações de hiperparâmetros melhor contribuem para os resultados. Vale evidenciar que os hiperparâmetros são diferentes entre os modelos e que a documentação de cada um deles deve ser consultada para melhor adequação. Destaca-se ainda que há pacotes, por exemplo, o “scikit-learn”, que permitem definir e testar vários

intervalos de hiperparâmetros automaticamente. Esse processo de testar vários hiperparâmetros para ver qual gera melhores resultados é chamado de “grid search” (Mehtab e Sen, 2020).

Como forma de exemplificar, apresenta-se por meio da Tabela 2 os hiperparâmetros definidos no modelo LightGBM.

Tabela 2. Hiperparâmetros utilizados com o modelo LightGBM

Parâmetro	Descrição
Boosting_type='gbdt'	
Objective='binary'	# Tarefa de aprendizagem
Metric='auc'	
Num_leaves=31	# Máximo de folhas por árvore
Max_depth=-1	# Profundidade máxima da árvore, -1 significa sem limite
Learning_rate=0.1	# Taxa de aprendizagem
N_estimators=100	# Número de árvores
Subsample_for_bin=200000	# Número de amostras para construção de caixas
Class_weight=None	# dicionário, “balanced” ou “none”
Min_split_gain=0.0	# Redução de perda mínima para redução adicional
Min_child_weight=0.001	# Soma mínima do peso da instância
Min_child_samples=20	# Número mínimo de dados necessários em uma folha filha
Subsample=1.0	# Proporção de subamostras de amostras de treinamento
Subsample_freq=0	# Frequência de subamostragem, <=0: desabilitado
Colsample_bytree=1.0	# Proporção de subamostragem de recursos
Reg_alpha=0.0	# Prazo de regularização L1 em pesos
Parâmetro	Descrição
Reg_lambda=0.0	# Prazo de regularização L2 em pesos
Random_state=42	# Número aleatório semente; padrão: C++ semente
N_jobs=-1	# Número de “threads” paralelo. -1 significa sem limite
Silent=False	
Importance_type='gain'	# padrão: 'split' or 'gain'

Fonte: Jansen (2020)

Para treinar e testar os modelos, criou-se um esquema de treino e teste (“cross validation”) da seguinte maneira: treinou-se 12 meses e testou-se o modelo no mês subsequente. Posteriormente, incrementou-se, em um mês, o período de treino e testou-se o mês subsequente, sempre mantendo 12 meses como treino e 1 mês como teste. A Figura 1 exemplifica o esquema dos períodos de treino e teste.



Figura 1. Exemplificação dos períodos de treino e teste
Fonte: Dados originais da pesquisa

Os desempenhos desses modelos podem ser avaliados empregando-se várias métricas. É importante que elas sejam selecionadas de forma que melhor se adaptem à tarefa de previsão e à estrutura da variável resposta.

Em tarefas de regressão, diferentes métricas de desempenho podem ser empregadas. As mais comuns são estas: “Mean Squared Error [MSE]”, “Mean Absolute Error [MAE]” e R2. Para as tarefas de classificação utilizadas no presente estudo, o método mais direto é comparar os resultados reais com os resultados previstos por meio de uma matriz de 2x2 chamada de matriz de confusão. A partir dela, muitas métricas de avaliação dos modelos podem ser geradas (Consoli et al., 2021). A Tabela 3 mostra a estrutura dessa matriz.

Tabela 3. Matriz de confusão

		Valor real	
		1	0
Valor previsto	1	TP	FP
	0	FN	TN

Fonte: Dados originais da pesquisa

Para os modelos de previsão que foram testados, a variável resposta deveria ser binária. Nesse sentido, não se desejava saber qual o retorno de uma ação para o próximo mês, mas, sim, se ele seria positivo ou negativo. Desse modo, as variáveis binárias foram criadas da seguinte forma: as ações com retornos maiores que zero receberam o valor 1 (um), senão o valor 0 (zero). Os retornos considerados nesse caso foram sempre referentes ao primeiro mês subsequente aos dados utilizados. Exemplo: para os indicadores criados com informações até 12/2021, utilizou-se o retorno do mês 01/2022 para a criação da variável dependente.

Depois de rodar os modelos, as ações recebem classificações. Assim, as que foram classificadas como retornos positivos e de fato apresentaram valor positivo são chamadas de “True Positive (TP)”. As ações que foram classificadas como retornos positivos, mas apresentaram retornos negativos são chamadas de “False Positive (FP)”. As ações

classificadas como retorno negativo e apresentaram retornos positivos são chamadas de “False Negative (FN)”. Por fim, as ações classificadas como retornos negativos e que de fato obtiveram resultados negativos são chamadas de “True Negative (TN)”. A partir dessas denominações, os seguintes indicadores puderam ser construídos por meio das form. (5) a (8):

$$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN} \tag{5}$$

$$\text{Precision} = \frac{TP}{TP+FP} \tag{6}$$

$$\text{Recall} = \text{Sensitivity} = \frac{TP}{TP+FN} \tag{7}$$

$$\text{F1 Score} = 2\frac{\text{Precision x Recall}}{\text{Precision} + \text{Recall}} \tag{8}$$

A “accuracy” (acurácia) mostra o percentual de previsões acertadas em meio a todas as previsões, ou seja, tanto eventos quanto não eventos. Já a “precision” (precisão) apresenta quais as previsões de eventos acertadas, entre as precisões feitas como evento. Essas duas medidas são muito interessantes para serem utilizadas no mercado acionário, sendo que a primeira é utilizada tanto para avaliar posições “long” (compradas) quanto posições “short” (vendidas a descoberto), e a segunda, somente para avaliação de posições “long”. O “recall” (sensitividade) é o indicador que mostra o percentual de acertos quando considerada a soma dos verdadeiros positivos com os falsos negativos. Por fim, “F1 score” é uma média harmônica criada a partir das métricas “precision” e “recall”.

Além das métricas citadas acima, que são geradas a partir da matriz de confusão, outras duas foram avaliadas: a função “log loss” e a “Area the Under the ROC Curve [AUC]”. A função “log loss” tem o objetivo de avaliar se o modelo faz previsões boas ou ruins. Ela mensura o desempenho de um modelo de classificação cuja saída é uma probabilidade. Apesar de ainda não haver um consenso entre os pesquisadores de maneira geral, segundo López de Prado (2018), essa é uma das melhores métricas para se utilizar no mercado financeiro. Quanto mais divergentes forem os valores previstos dos valores atuais, maior será o valor da “log loss”, isto é, para essa métrica, quanto menor o valor, melhores são as previsões. De acordo com Ghatak (2019), ela pode ser calculada com a form. (9).

$$H(y,y_hat) = \sum_i y_i \log \frac{1}{y_hat_i} - \sum_i y_i \log y_hat_i \quad (9)$$

Para entender o conceito de curva ROC e o de AUC, é necessário conhecer o conceito de especificidade. Segundo Fávero e Belfiore (2017), a especificidade refere-se ao percentual de acerto, para um dado “cutoff”, considerando-se apenas as observações que não são eventos. Utilizando-se a matriz de confusão, a especificidade pode ser calculada utilizando a form. (10):

$$\text{Specificity} = \frac{TN}{TN + FP} \quad (10)$$

onde: TN significa true negative e FP significa false positive, da mesma forma que foram abordados nas forms. (5) a (9).

A curva ROC mostra o comportamento propriamente dito do “trade off” entre a sensitividade e a especificidade, e, ao trazer, no eixo das abscissas, os valores de (1-"specificity"), apresenta formato convexo em relação ao ponto (0,1). Nesse sentido, um determinado modelo com maior área abaixo da curva ROC apresenta maior eficiência global de previsão (Fávero e Belfiore, 2017). Na próxima seção, apresenta-se os resultados da pesquisa.

Resultados e Discussão

Na Tabela 4, é possível observar a análise descritiva das variáveis explicativas utilizadas nos modelos. Observa-se, por exemplo, que foram trabalhados cinco anos (de 2017 a 2021), correspondente a 60 meses, e que as empresas estão distribuídas em 18 setores em conformidade com a classificação “North American Industry Classification System [NAICS]”.

Tabela 4. Análise descritiva das variáveis explicativas

(continua)

Variável	Quant.	Média	Desvio Padrão	Min.	25%	50%	75%	Max.
Ano	5			2017				2021
Mês	60			1				12
Setor	18							
Return_1m	14640	0,0177	0,1455	-0,3792	-0,0557	0,0000	0,0724	0,6157
Return_2m	14640	0,0135	0,1066	-0,2855	-0,0404	0,0023	0,0612	0,4142
Return_3m	14640	0,0118	0,0880	-0,2362	-0,0330	0,0050	0,0526	0,3228
Return_6m	14640	0,0115	0,0597	-0,1623	-0,0203	0,0075	0,0407	0,2105

Tabela 5. Análise descritiva das variáveis explicativas

(conclusão)

Variável	Quant.	Média	Desvio Padrão	Min.	25%	50%	75%	Max.
Return_9m	14640	0,0127	0,0486	-0,1264	-0,0135	0,0094	0,0370	0,1709
Return_12m	14640	0,0132	0,0419	-0,1042	-0,0100	0,0106	0,0353	0,1482
Momentum_2	14640	-0,0042	0,1060	-0,8696	-0,0467	0,0000	0,0455	0,7934
Momentum_3	14640	-0,0059	0,1233	-0,8519	-0,0578	0,0000	0,0560	0,7020
Momentum_6	14640	-0,0062	0,1360	-0,7780	-0,0617	0,0024	0,0644	0,5897
Momentum_9	14640	-0,0050	0,1391	-0,7422	-0,0609	0,0045	0,0654	0,5501
Momentum_12	14640	-0,0045	0,1396	-0,7199	-0,0585	0,0052	0,0651	0,5274
Momentum_3_12	14640	0,0014	0,0772	-0,4191	-0,0372	0,0019	0,0408	0,3844
Return_1m_t-1	14616	0,0173	0,1453	-0,3792	-0,0562	0,0000	0,0714	0,6157
Return_1m_t-2	14592	0,0169	0,1455	-0,3792	-0,0567	0,0000	0,0711	0,6157
Return_1m_t-3	14568	0,0190	0,1454	-0,3792	-0,0543	0,0000	0,0729	0,6157
Return_1m_t-4	14543	0,0199	0,1452	-0,3792	-0,0526	0,0000	0,0732	0,6157
Return_1m_t-5	14516	0,0208	0,1455	-0,3792	-0,0517	0,0000	0,0738	0,6157
Return_1m_t-6	14488	0,0242	0,1464	-0,3792	-0,0489	0,0000	0,0769	0,6157

Fonte: Resultados originais da pesquisa

A Tabela 5 mostra como estão classificadas as informações na variável resposta. Conforme exposto na metodologia do trabalho, as variáveis binárias apresentadas nessa ilustração foram criadas a partir dos retornos das ações. Observa-se, por exemplo, que 53,3% dos retornos foram classificados como 0 e 46,7%, como 1.

Tabela 6. Distribuição das frequências da variável dependente

Variável Y	Quant.	Perc.
Retorno negativo ou zero (0)	7805	0.5331
Retorno positivo (1)	6835	0.4669
Total	14640	

Fonte: Resultados originais da pesquisa

Por fim, finalizando essa parte introdutória dos dados, observa-se, por intermédio da Tabela 6, em quais setores estão enquadradas as empresas utilizadas na amostra. Destaca-se que a classificação NAICS é bastante ampla e que só uma pequena parte dos setores aparece na pesquisa.

Tabela 7. Quantidade de empresas utilizadas na pesquisa de acordo com cada setor

(continua)

Setor NAICS	Quant.
Administração de empresas e empreendimentos	9
Agricultura, pecuária, silvicultura, pesca e caça	3
Artes, entretenimento e recreação	1
Assistência médica e social	7
Comércio atacadista	4
Comércio varejista	11

Tabela 8. Quantidade de empresas utilizadas na pesquisa de acordo com cada setor (conclusão)

Setor NAICS	Quant.
Construção	18
Educação	5
Empresa de eletricidade, gás e água	38
Hotel e restaurante	1
Imobiliária e locadora de outros bens	11
Indústria manufatureira	82
Informação	10
Mineração, exploração de pedreiras e extração de petróleo e gás	6
Serviços de apoio a empresas e gerenciamento de resíduos e remediação	3
Serviços financeiros e seguros	27
Serviços profissionais, científicos e técnicos	3
Transporte e armazenamento	11

Fonte: Resultados originais da pesquisa

Os resultados da pesquisa são mostrados na Tabela 7 de maneira resumida, contendo somente o período de testes de cada métrica. O modelo criado a partir do algoritmo CatBoost apresentou melhores indicadores em praticamente todas as métricas. Conforme será comentado a seguir, notou-se certa similaridade das precisões no mercado brasileiro com estudos realizados em outros países. Apesar de a vantagem ser aparentemente pequena do CatBoost em relação aos outros, no mercado financeiro isso pode representar grandes valores.

Tabela 9. Resumo dos resultados dos modelos no período de teste

Métrica	AUC	Accuracy	F1	Log loss	Precision	Recall
CatBoost	0.565053	0.559442	0.548607	-0.69806	0.635065	0.535835
Gradient boosting	0.555262	0.512103	0.469639	-0.78902	0.587741	0.519400
AdaBoost	0.552201	0.509216	0.479508	-0.69271	0.627196	0.522487
LightGBM	0.551736	0.531373	0.467815	-0.74044	0.649184	0.497354
XGBoost	0.547973	0.533237	0.481243	-0.71442	0.618827	0.511785

Fonte: Resultados originais da pesquisa

Além dos resultados das métricas apresentados na Tabela 7, há ainda a necessidade de se avaliar quais são as outras vantagens dos modelos. No que se refere ao LightGBM, por exemplo, o modelo tem um nível de resultados ligeiramente inferior quando comparado aos outros modelos aqui empreendidos. No entanto, é muito mais rápido para convergir do que os demais, uma vantagem significativa ao se trabalhar com um grande volume de dados, em especial quando se deseja avaliar intervalos de hiperparâmetros. De acordo com testes realizados em vários “datasets” públicos, ele se mostrou até 20 vezes mais rápido no treinamento do que os modelos anteriores (Ke et al., 2017).

Yin et al. (2021) utilizaram o modelo LightGBM para prever a tendência de quatro empresas listadas no mercado americano. Com informações diárias referentes ao período de

janeiro de 2015 a outubro de 2020, eles alcançaram um AUC de 0,87. O resultado encontrado pelos autores é bastante superior ao encontrado no presente estudo, o que talvez se justifique pelo fato dos autores utilizarem empresas, escala de tempo e período diferentes. Tais divergências poderiam ser exploradas em estudos futuros.

Xu et al. (2021) empregaram os modelos XGBoost, Light GBM e CatBoost para prever o comportamento dos seis maiores índices de ações do mercado chinês. Os autores fizeram previsões diárias do fechamento dos índices no período de 2009 a 2020, sendo 70% desse intervalo de tempo como treino e o restante como teste. As características que serviram de variáveis explicativas para os modelos foram criadas a partir das cotações de diferentes períodos, sendo a mínima de um minuto e a máxima de 60 dias. Dessa forma, os autores alcançaram a acurácia de 0,53 para o XGBoost, 0,52 para o Light GBM e 0,55 para o CatBoost. Apesar de não haver muitas similaridades entre o mercado chinês e o brasileiro, o resultado das previsões do presente estudo foi muito parecido com o encontrado por Xu et al. (2021).

Jabeur et al. (2021) testaram esses modelos no modo de regressão de modo diferente do realizado no presente trabalho, no qual se utilizou o modo classificação. O objetivo dos autores foi prever o retorno do ouro com base em indicadores de outras “commodities”. Para isso, eles coletaram informações mensais para o período de janeiro de 1986 a dezembro de 2019. Diferentemente dos achados no presente estudo, o melhor modelo preditivo para os autores foi o XGBoost, seguido pelo CatBoost, Random Forest e LightGBM.

Sun et al. (2020) aplicaram os modelos LightGBM, Random Forest e SVM para a previsão do retorno de criptomoedas. Apesar de utilizarem uma amostra consideravelmente pequena (01/2018 a 06/2018), a acurácia foi promissora, a qual mostrou maior taxa de acerto para o LightGBM.

A Figura 2 apresenta os resultados deste estudo sob uma perspectiva mais ampla. Nessa ilustração, é possível observar que os valores variam consideravelmente em torno das médias.

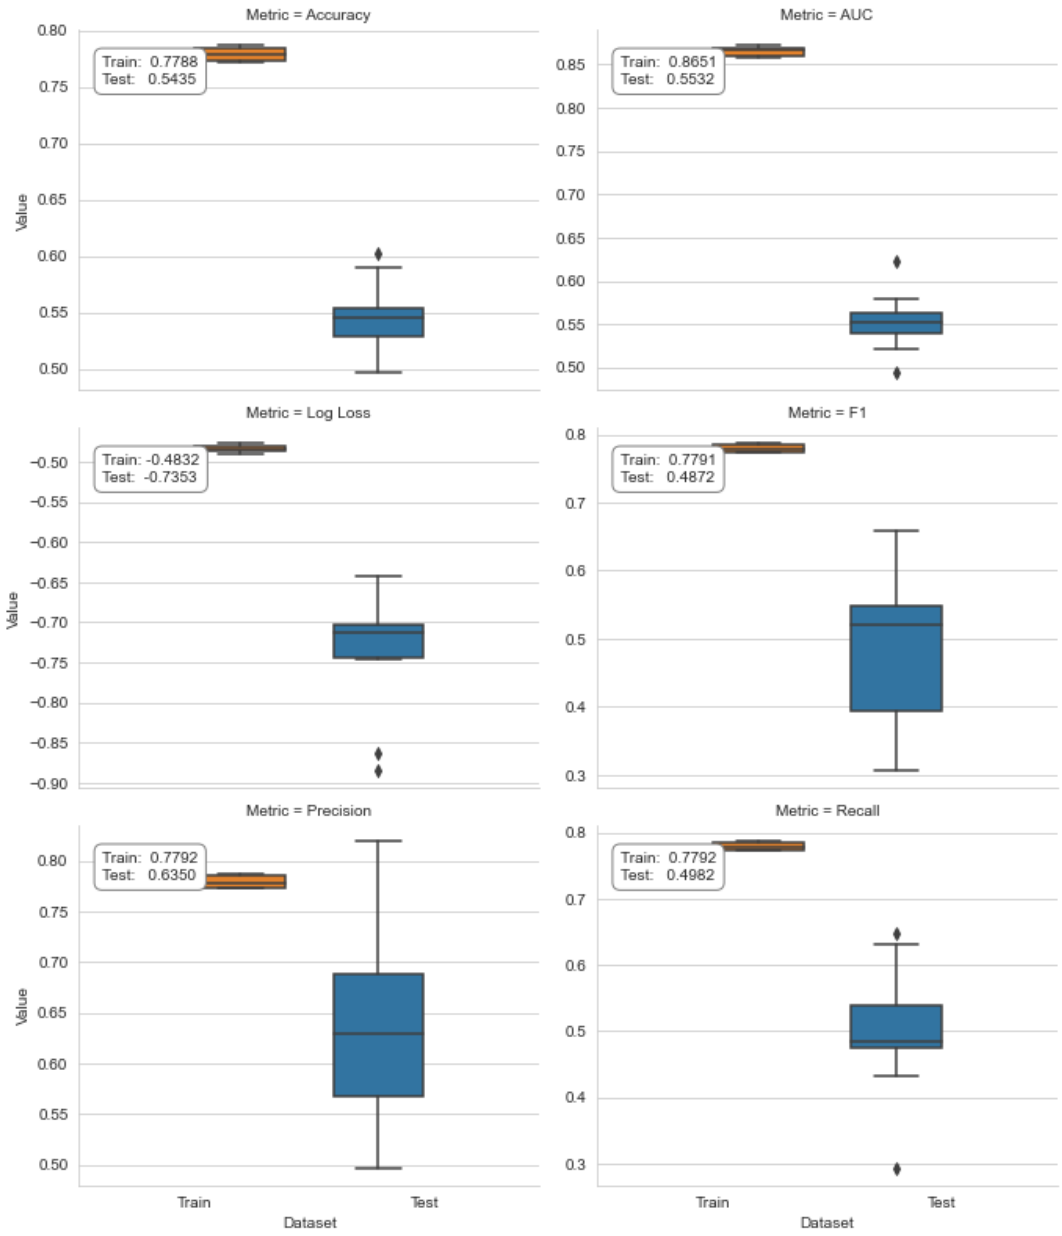


Figura 2. Gráfico do comportamento da métricas nos períodos de treino e teste
Fonte: Resultados originais da pesquisa

Por meio da Figura 2, pode-se verificar que a variação no período de treino é pequena, fator que já era esperado. Observa-se ainda que há grande variação nos indicadores nos períodos de teste. Compreende-se que três questões poderiam ser abordadas futuramente para minimizar essa variação e tornar os modelos mais estáveis e precisos. São elas: aumento do período de treino, um aumento do número de variáveis explicativas (ou mesmo um melhor refinamento na escolha de tais variáveis para a composição do modelo), bem como uma modificação da frequência de negócios para a escala diária.

Por fim, a Figura 3 mostra a importância de cada uma das características testadas nos modelos.

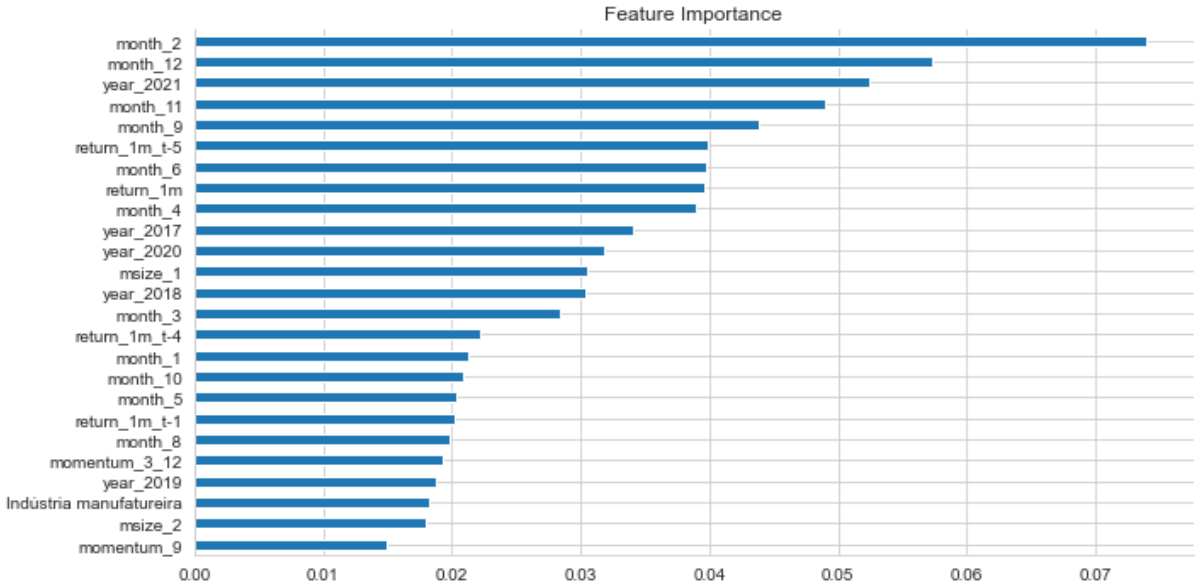


Figura 3. Impacto das variáveis no modelo
Fonte: Resultados originais da pesquisa

Nota-se, na Figura 3, que a característica que mais influenciou os retornos foi a variável categoria month_2 (referente ao mês de fevereiro), seguida do month_12 e year_2021 (representando o ano de 2021).

Apesar de os resultados terem se apresentado muito próximos de um palpite aleatório, alguns autores têm defendido que, quando se faz um grande volume de negócios utilizando um sistema de “High Frequency Trading [HFT]”, uma acurácia entre 51% e 52% é suficiente para se obter lucros. Não é o caso do presente trabalho, em que se testou retornos na escala mensal.

Muitas companhias comerciais e instituições de pesquisa têm desenvolvido preditores de ações baseados em modelos estatísticos e, com isso, espera-se obter informações mais regulares na análise dos dados históricos ou direcionamento no processo decisório (Yin et al., 2021).

Este estudo utilizou como amostra as ações listadas na B3. Dadas as características simples dos dados utilizados (preço de fechamento), esses algoritmos podem ser aplicados também em outros ativos, por exemplo, “Exchange Traded Fund [ETF]”, títulos públicos, criptomoedas, etc.

Considerações Finais

O estudo alcançou o objetivo e mostrou as acurácias de diferentes modelos de “machine learning” no mercado de ações brasileiro. O modelo gerado a partir do algoritmo

CatBoost foi o que apresentou melhores resultados em praticamente todas as métricas, especial na acurácia e na AUC. Destaca-se que esse algoritmo é o mais novo entre os testados e representa o estado da arte em termos de algoritmos baseados em árvores de decisão.

A principal dificuldade encontrada no melhor modelo foi a necessidade de utilização de [GPU] para a obtenção de um bom desempenho, dispositivo que ainda não é comum em computadores pessoais. Estima-se que em poucos anos isso não deverá ser um problema, haja vista a velocidade de desenvolvimento dos dispositivos de “hardware”. Nesse sentido, um processo que exige agilidade nas respostas demandará de alto poder de processamento computacional. Uma das limitações foi não encontrar outros estudos no mercado brasileiro utilizando o modelo Catboost, o que dificultou a comparabilidade com outros estudos nacionais.

Sugere-se que, para trabalhos futuros, sejam explorados outros indicadores técnicos como variáveis explicativas. Eles podem ser gerados a partir de diferentes pacotes tanto para linguagem Python quanto para R. Conforme destacado por Xu et al. (2021), o desempenho das previsões no mercado financeiro depende não somente dos algoritmos, mas também das características do mercado e das ações que foram inseridas nele. Sugere-se, em especial, o cálculo e a inclusão dos cinco fatores de Fama-French, que são largamente estudados e melhoram o poder preditivo de alguns cenários.

Referências

Ben Abdelaziz, F.; Mrad, F. 2021. Multiagent systems for modeling the information game in a financial market. International Transactions in Operational Research 0, itor.12944: 1-14. Disponível em: <https://doi.org/10.1111/itor.12944>. Acesso em: 10 mar. 2022.

Brasil, Bolsa, Balcão [B3]. 2021. Investidor Pessoa Física: total de investidor pessoa física cresce 43% no primeiro semestre, mostra estudo da B3. Disponível em: <https://www.b3.com.br/pt_br/noticias/porcentagem-de-investidores-pessoa-fisica-cresce-na-b3.htm>. Acesso em: 01 abr. 2022.

Chen, T.; Guestrin, C. 2016. XGBoost. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining 42(8): 785-794. Disponível em: <https://doi.org/10.1145/2939672.2939785>. Acesso em: 10 mar. 2022.

Chen, Y.; Li, X.; Sun, W. 2020. Research on stock selection strategy based on AdaBoost algorithm. In: IV International Conference on Computer Science and Application Engineering, 2020, Sanya, Hainan, China. Anais… p. 1-5. Disponível em: <https://doi.org/10.1145/3424978.3425084>. Acesso em: 10 mar. 2022

Consoli, S.; Recupero, D.R.; Saisana, M. 2021. Data science for economics and finance: methodologies and applications. Springer, Chan, Zug, Switzerland. Disponível em: <https://doi.org/10.1007/978-3-030-66891-4>. Acesso em: 10 mar. 2022.

Elmsili, B.; Outtaj, B. 2021. Predicting stock market movements using machine learning techniques. International Journal of Accounting, Finance, Auditing, Management and Economics 2(3): 390-405. Disponível em: <https://doi.org/https://doi.org/10.5281/zenodo.4869914>. Acesso em: 11 mar. 2022.

Fama, E.F. 1998. Market efficiency, long-term returns, and behavioral finance. Journal of Financial Economics 49(3): 283-306. Disponível em: <https://doi.org/10.1016/s0304-405x(98)00026-9>. Acesso em: 01 mar. 2022.

Fávero, L.P.; Belfiore, P. 2017. Manual de análise de dados: estatística e modelagem multivariada com Excel®, SPSS® e Stata®. LTC, Rio de Janeiro, RJ, Brasil.
Freund, Y.; Schapire, R.E. 1997. A decision-theoretic generalization of on-line learning and an application to boosting. Journal of Computer and System Sciences 55(1): 119-139. Disponível em: <https://doi.org/10.1006/jcss.1997.1504>. Acesso em: 15 fev. 2022.

Ghashami, F.; Kamyar, K. 2021. Performance evaluation of ANFIS and GA-ANFIS for predicting stock market indices. International Journal of Economics and Finance 13(7): 1-6. Disponível em: <https://doi.org/10.5539/ijef.v13n7p1>. Acesso em: 13 fev. 2022.

Ghatak, A. 2019. Deep learning with R. Springer, Singapore. Disponível em: <https://doi.org/10.1007/978-981-13-5850-0>. Acesso em: 01 fev. 2022.

Guerard, J.B.; Xu, G.; Wang, Z. 2019. Portfolio and investment analysis with sas: financial modeling techniques for optimization. SAS Institute Inc., Cary, North Carolina, USA.

Haq, A.U.; Zeb, A.; Lei, Z.; Zhang, D. 2021. Forecasting daily stock trend using multi-filter feature selection and deep learning. Expert Systems with Applications 168: p.1-9. Disponível em: <https://doi.org/10.1016/j.eswa.2020.114444>. Acesso em: 12 fev. 2022.

Hastie, T.; Tibshirani, R.; Friedman, J. 2009. The elements of statistical learning: data mining, inference, and prediction. Springer, New York, NY, USA. Disponível em: <https://doi.org/10.1007/978-0-387-84858-7>. Acesso em: 10 fev. 2022.

Jabeur, S.B.; Mefteh-Wali, S.; Viviani, J.-L. 2021. Forecasting gold price with the XGBoost algorithm and SHAP interaction values. Annals of Operations Research, p. 1-2. Disponível em: <https://doi.org/10.1007/s10479-021-04187-w>. Acesso em: 25 jan. 2022.

Jansen, S. 2020. Machine learning for algorithmic trading: predictive models to extract signals from market and alternative data for systematic trading strategies with Python. Packt Publishing, Birmingham, West Midlands, England.

Ke, G.; Meng, Q.; Finley, T.; Wang, T.; Chen, W.; Ma, W.; Ye, Q.; Liu, T.Y. 2017. LightGBM: a highly efficient gradient boosting decision tree. Advances in Neural Information Processing Systems 30: 3147-3155.

Liu, Y.; Cao, C.; Huang, W.; Hao, S. 2021. A deep neural network based model for stock market prediction. In: II International Conference on Big Data, Artificial Intelligence and Internet of Things Engineering (ICBAIE), 2021, Nanchang, China. Anais… p. 320-323. Disponível em: <https://doi.org/10.1109/ICBAIE52039.2021.9390010>. Acesso em: 15 jan. 2022.

López de Prado, M. 2018. Advances in financial machine learning. John Wiley & Sons, Hoboken, New Jersey, USA.

Mehtab, S.; Sen, J. 2020. Stock price prediction using CNN and LSTM-Based deep learning models. International Conference on Decision Aid Sciences and Application (DASA), Bahrein. Anais… p. 447-453. Disponível em: <https://doi.org/10.1109/DASA51403.2020.9317207>. Acesso em: 15 jan. 2022.

Mo, H.; Sun, H.; Liu, J.; Wei, S. 2019. Developing window behavior models for residential buildings using XGBoost algorithm. Energy and Buildings UCL Discovery 205: p. 1-8, artigo 109564. Disponível em: <https://doi.org/10.1016/j.enbuild.2019.109564>. Acesso em: 10 jan. 2022.

Nabipour, M., Nayyeri, P., Jabani, H., Mosavi, A., Salwana, E., & S., S. (2020). Deep Learning for Stock Market Prediction. Entropy, 22(8), 840. Disponível em: <https://doi.org/10.3390/e22080840>. Acessom em: 06 jul. 2022.

Prokhorenkova, L.; Gusev, G.; Vorobev, A.; Dorogush, A.V.; Gulin, A. 2018. CatBoost: unbiased boosting with categorical features. In: XXXII Conference on Neural Information Processing Systems, 2018, Montreal, Canada. Anais… p. 1-23.

Rajkar, A.; Kumaria, A.; Raut, A.; Kulkarni, N. 2021. Stock market price prediction and analysis. International Journal of Engineering Research & Technology 10(6): p. 115-119.

Schapire, R.E.; Freund, Y. 2013. Boosting: foundations and algorithms. Kybernetes 42(1): 164-166. Disponível em: <https://doi.org/10.1108/03684921311295547>. Acesso em: 12 jan. 2022.

Sun, X.; Liu, M.; Sima, Z. 2020. A novel cryptocurrency price trend forecasting model based on LightGBM. Finance Research Letters 32: p. 1-6. Disponível em: <https://doi.org/10.1016/j.frl.2018.12.032>. Acesso em: 12 jan. 2022.

Wade, C. 2020. Hands-on gradient boosting with xgboost and scikit-learn: perform accessible machine learning and extreme gradient boosting with Python. Packt Publishing. Birmingham, West Midlands, England.

Xu, R.; Chen, Y.; Xiao, T.; Wang, J.; Wang, X. 2021. Predicting the trend of stock index based on feature engineering and CatBoost model. International Journal of Financial Engineering 8(2): p. 1-17. Disponível em: <https://doi.org/10.1142/s2424786321500274>. Acesso em: 15 jan. 2022.

Yin, L.; Li, B.; Li, P.; Zhang, R. 2021. Research on stock trend prediction method based on optimized random forest. CAAI Transactions on Intelligence Technology, september: p. 1-11. Disponível em: <https://doi.org/10.1049/cit2.12067>. Acesso em: 17 jan. 2022.